



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

공학 석사학위 논문

회전교차로 충돌 예측의 성능 개선을 위한
절차적 도로 생성 및 데이터 선별 연구

**Procedural Road Generation and
Effective Information Gain-based Data
Selection for Collision Prediction
at Roundabouts**

아주대학교 대학원

D.N.A 플러스융합학과

임동현

회전교차로 충돌 예측의 성능 개선을 위한
절차적 도로 생성 및 데이터 선별 연구

**Procedural Road Generation and
Effective Information Gain-based Data
Selection for Collision Prediction
at Roundabouts**

지도교수 송 봉 섭

이 논문을 공학 석사학위 논문으로 제출함.

2026 년 8 월

아 주 대 학 교 대 학 원

D.N.A플러스융합학과

임 동 현

임동현의 공학 석사학위 논문을 인준함.

심사위원장 오 상 윤 인

심 사 위 원 송 봉 섭 인

심 사 위 원 이 상 현 인

아 주 대 학 교 대 학 원

2026년 8월

- 본 문 요약 -

본 연구에서는 딥러닝 기반 차량 간 충돌 예측 모델이 회전교차로와 같은 복잡한 도로 기하 환경에서 보이는 성능 한계를 개선하기 위한 데이터 증강 및 증강 데이터 선별 방법을 통합하였다. 이러한 복잡한 도로 기하 환경은 실 세계 주행 데이터에서 극히 드물게 나타나 학습 데이터가 도로 유형에 따라 롱테일(long-tailed) 분포를 이루며, 그 결과 비전 센서의 도로 기하 인지 불확실성에서 기인한 오경보(false positive, FP)가 잔존한다. 이러한 불균형은 기존 학습 데이터 내부의 선별만으로는 해소되지 않는다.

먼저 실 도로 주행 데이터 분포의 한계를 보완하기 위한 데이터 증강 방법을 제안한다. 안전 분석을 통해 보강이 필요한 오경보 원인을 식별한 뒤, 학습 데이터에 부재한 회전교차로 시나리오를 절차적 도로 생성으로 직접 생성하고 실 도로 오경보에서 관측된 차량 거동 표본을 결합하여 롱테일 증강 데이터셋을 구축한다. 이를 통해 재조합 기반 증강 기법이 생성하지 못하는 복잡한 도로 기하 데이터를 확보한다.

다음으로 생성된 증강 데이터를 무분별하게 사용할 때 발생하는 성능 저하를 방지하기 위한 정량적 데이터 선별 방법을 제안한다. 증강 데이터가 원본 분포에 더하는 정보의 풍부함과 분포 이동 사이의 균형을 유효 정보 이득(effective information gain, EIG)으로 정량화하고, 결합 EIG가 목표값에 수렴하도록 증강 데이터를 선별하여 학습에 추가한다. 이를 통해 모델 구조의 변형 없이 학습 데이터 보강만으로 롱테일 도로 유형 중 회전교차로 상황을 개선하기 위한 데이터 선별 방법을 제안한다. 실도로 및 가상 주행 데이터에 대

한 정량 평가 결과, 제안 기법은 기준 모델 대비 정확도를 97.0%에서 97.6%로 향상시키고 실도로 잔존 오경보를 10 건에서 3 건으로 70% 저감하여 비교 증강 기법 중 최저 오경보율(전체 평가 데이터 기준 FPR 3.65%→2.31%)을 달성하였으며, 이 과정에서 본 연구가 표적으로 한 회전교차로 도로 기하 기인 오경보는 평가 데이터 기준 3 건에서 0 건으로 해소되었다. 다만 미검출은 43 건에서 68 건(FNR 1.66%→2.62%)으로 증가하여 오경보 저감과 상충 관계에 있다.

- 본 문 목 차 -

1. 서론.....	1
1.1 연구 배경.....	1
1.2 연구 동향.....	3
1.3 문제 정의.....	7
2. 충돌 예측을 위한 회전교차로 시나리오 생성.....	14
2.1 학습 데이터 선정.....	14
2.2 충돌 예측 모델의 안전 분석.....	21
2.3 시나리오 선정.....	24
2.4 도로망 생성.....	27
2.5 차량 파라미터 분포 추정 및 샘플링.....	33
3. 목표 EIG 기반 증강 데이터 선별.....	37
3.1 Effective Information Gain.....	37
3.2 증강 데이터 분류.....	40
3.3 증강 데이터 선별.....	43
3.4 검증 및 평가.....	49
4. 결론.....	59
5. 참고 문헌.....	62

- 그림 목 차 -

Figure 1-1 Accuracy and residual FP per active-learning iteration	9
Figure 1-2 Roundabout false-positive example under low lane-confidence	11
Figure 1-3 Road-type class distribution and the long-tail position of roundabouts.....	12
Figure 1-4 Overall framework of the proposed roundabout augmentation and target-EIG selection.....	13
Figure 2-1 Multi-sensor data acquisition platform and driving routes	16
Figure 2-2 HARA/SOTIF-based false-positive classification flowchart.....	22
Figure 2-3 Residual road-geometry FP cases and the two logical scenarios.....	26
Figure 2-4 Procedural generation of complex roundabouts (3 steps).....	28
Figure 2-5 Diversity and realism analysis of generated roundabout road networks.....	30
Figure 2-6 Normalized radial deviation and radius change distributions of PCG and FP roundabout road networks	32
Figure 2-7 Parameter distributions of FOT-FP data and fitted GMMs.....	36
Figure 3-1 Dimensionality reduction and clustering of augmented embeddings	41
Figure 3-2 Cumulative combined EIG converging to the target as subsets are added	45
Figure 3-3 $\Delta mTTCP$ distributions of augmented training data compared with RAB and all false positives	48
Figure 3-4 Definition of decision time	50
Figure 3-5 Road geometry uncertainty false-positive distribution	57

- 표 목 차 -

Table 1-1 Residual FP analysis by cause mode across active-learning iterations	10
Table 2-1 Summary of virtual-driving and real-driving data.....	16
Table 2-2 Statistics of virtual-driving and real-driving dataset split	19
Table 2-3 Number of training data across active-learning iterations.....	20
Table 2-4 HARA/SOTIF-based false-positive cause classification and recommended actions	23
Table 3-1 Composition of the target-EIG-selected augmented training dataset.....	46
Table 3-2 Evaluation metrics for collision prediction performance	50
Table 3-3 Collision prediction performance on all data	52
Table 3-4 Collision prediction performance on virtual-driving data	52
Table 3-5 Collision prediction performance on real-driving data.....	53
Table 3-6 HARA/SOTIF-based false-positive classification on real-driving data	56

1. 서론

1.1 연구 배경

자율주행 기술의 발전에 따라 운전자 보조의 적용 범위는 고속도로와 같은 비교적 단순한 환경에서 도심 주행과 같은 복잡하고 도전적인 환경으로 확대되고 있다. 도심 환경 가운데 회전교차로(roundabout)와 교차로는 진입·합류·선회가 동시에 일어나 주행 난이도가 높은 구간으로, 차량 안전을 위한 첨단 운전자 보조 시스템(advanced driver assistance system, ADAS)의 적용 또한 점차 확대되고 있다. ADAS는 충돌 위험을 사전에 감지하고 대응하여 사고를 방지하는 능동 안전 기술로서, 종방향과 횡방향 제어를 지속적으로 보조하는 방향으로 고도화되고 있다.

이러한 흐름에서 종·횡 제어를 지속적으로 보조하는 운전자 보조 시스템(driver control assistance systems, DCAS)을 규정하는 UN Regulation No. 171은 충돌 예측(collision prediction) 기능을 핵심 요건으로 요구하며 [1, 2], 대표적 ADAS 기능인 자동 긴급 제동(AEB)이 전방 충돌 사고를 약 43~50% 저감하는 것으로 보고되어 [3] 충돌을 사전에 예측·대응하는 기술의 사고 저감 효과가 확인된다.

그러나 이러한 보조 시스템의 성능은 지정된 작동 설계 영역(operational design domain, ODD) 내로 한정되어 회전교차로와 같은 복잡한 도로 구조에

서는 보장되지 않으며 [4], 이때의 충돌 회피 실패는 시스템 고장이 아니라 의도된 기능 자체의 한계에서 비롯되는 경우가 많다 [5]. 시스템 고장 기반 위험을 다루는 ISO 26262 와 달리 ISO 21448 SOTIF 는 의도된 기능의 한계에서 발생하는 잠재적 위험을 다루고, 최근 ISO/PAS 8800(2024)은 이를 인공지능 시스템으로 확장한다 [6, 7, 8]. SOTIF 안전성 확보의 핵심은 미식별·위험(unknown·hazardous) 영역까지 시나리오 커버리지를 확장하는 것이며, 이렇게 드문 위험 상황은 실세계 데이터 분포상 롱테일(long-tail)에 해당한다.

기존의 딥러닝 기반 충돌 예측 연구는 주로 전체 데이터셋에 대한 평균적인 예측 성능 향상에 초점을 맞추어 왔으며, 실 도로 주행 데이터가 갖는 롱테일(long-tailed) 분포 특성을 충분히 반영하지 못하는 한계가 있다 [12, 13, 15]. 특히 능동 학습(active learning) 기반의 선행 연구는 모델이 오판단한 기존 데이터 샘플을 반복적으로 재학습하는 방식에 머무르기 때문에 [32], 회전교차로와 같이 학습 데이터에 부재하거나 극히 드문 복잡 도로 기하에 대해서는 근본적인 데이터 부족 문제를 해결하지 못한다. 그 결과 복잡한 도로 기하에서 기인한 오경보(false positive, FP)가 잔존하며, 학습 데이터 내부의 선별만으로는 이를 해소하기 어렵다.

이에 본 연구에서는 부족한 복잡 도로 기하 데이터를 절차적 생성으로 직접 보강하고, 유효 정보 이득(effective information gain, EIG) 기반의 정량적 선별로 학습에 유효한 데이터만을 선택함으로써, 제한된 실 도로 데이터 환경에서도 모델 구조의 변경 없이 충돌 예측 모델의 롱테일 성능을 개선하는 것을 목표로 한다.

1.2 연구 동향

충돌 예측은 주변 차량의 거동과 도로 환경으로부터 충돌 발생 가능성을 사전에 판단하는 기술로, 입력 표현과 모델 구조에 따라 다양한 접근이 연구되어 왔다.

위험 평가를 위한 충돌 예측 및 모션 예측(motion prediction) 연구는 크게 물리 기반(physical-based), 기동 기반(manuever-based), 상호작용 인지(interaction-aware) 방법으로 구분된다. 물리 기반 방법은 CV/CA·CTRA 등의 운동 모델과 칼만 필터로 상태를 외삽하여 계산 효율이 높으나 차량 간 상호작용을 반영하지 못해 복잡·희소 상황에서 정확도가 떨어지고 [16, 17, 18], 기동 기반 방법은 사전 정의된 기동을 인식하여 다중 모드 장기 예측이 가능하나 기동 집합에 의존하고 상호작용 반영이 제한적이다 [19, 20].

이에 비해 상호작용 인지 방법은 다수 차량의 상호작용을 LSTM, CNN, 트랜스포머(transformer)와 같은 딥러닝 모델로 학습하여 충돌과 궤적을 직접 예측하므로, 복잡한 상호작용이 존재하는 장면에서 높은 표현력과 예측 정확도를 보인다 [21, 22]. 다만 이러한 학습 기반 방법은 대량의 데이터에 의존하며, 학습 데이터에 드물게 나타나는 롱테일 상황에서는 성능이 취약하다는 한계를 가진다. 따라서 다양한 상황을 충분히 포함하는 학습 데이터를 확보하는 것이 상호작용 인지 기반 충돌 예측 모델의 성능을 좌우하는 핵심 요소가 된다. 한편 회전교차로 환경에 특화된 공개 거동 데이터로는 드론 기반으로 취

득된 round 데이터셋 [39]이 있으나, 충돌·프리크래시 이벤트를 포함하지 않아 충돌 예측 모델의 학습에 직접 활용하기는 어렵다.

본 연구가 대상으로 하는 상호작용 인지(interaction-aware) 계열의 합성곱 신경망 기반 충돌 예측 모델(collision probability convolutional neural network, CP-CNN)은 주변 차량의 상태·예측값과 물리 기반 충돌 확률을 조감도(bird's-eye view) 형태의 동적 의미 지도(dynamic semantic map, DSM) 이미지로 추상화하여 입력으로 사용한다 [21]. 충돌 발생 시나리오를 프리크래시(pre-crash)로 정의하여 충돌 1.5 초 이전 시점(t1)부터 충돌 시점(t2) 사이에 충돌 여부와 충돌 부위(collision mode)를 예측한다. 본 연구에서는 학습 성능을 정확히 평가하기 위해 네트워크 구조는 동일하게 사용하되 출력에 이중 한계법(double threshold)을 적용하는 후처리 부분은 제외한다.

데이터 중심 계열의 정보 증강은 지식 전이(knowledge transfer)와 데이터 증강(data augmentation)으로 나뉜다. 지식 전이는 head 클래스의 통계 정보를 tail로 이전하나 head-tail 관계가 명확해야 동작하여 이진 분류·자율주행 도메인에 직접 적용하기 어려운 반면 [23, 24], 데이터 증강 계열은 mixup·CutMix 등을 롱테일 분포에 맞게 재조합·변형하는 방법으로 구현이 단순하고 외부 지식 의존성이 낮아 일반화가 용이하다 [25, 26].

대표적인 데이터 증강 기법인 Remix 와 CMO(context-rich minority oversampling)는 기존 샘플을 롱테일 분포에 맞게 혼합·재조합한다. Remix 는 두 이미지를 선형 결합하되 특징과 레이블의 혼합 비율을 분리하여 레이블을 소수(tail) 클래스 쪽으로 가중 배정함으로써 결정 경계를 다수 클래스 쪽으로

이동시키고, CMO 는 소수 클래스 전경 객체를 다수 클래스 이미지에 CutMix 로 합성하여 다양한 배경을 갖는 소수 클래스 샘플을 생성한다 [25, 26].

두 기법을 충돌 예측 도메인에 적용하는 경우를 구체적으로 살펴보면 그 한계가 분명해진다. Remix 를 자율주행 도메인에 적용하면 tail 에 해당하는 희소 시나리오의 DSM 과 head 에 해당하는 일반 주행 상황의 DSM 을 선형 혼합하게 되는데, 이 경우 두 장면이 겹쳐진 합성 이미지가 만들어진다. CMO 를 적용하면 head 장면을 배경으로 하여 tail 시나리오의 전경 패치를 붙이는 방식으로 합성 이미지를 생성한다. 그러나 충돌 예측의 입력은 도로 기하와 차량 거동이 물리적으로 일관되어야 하는 조감도 표현이므로, 두 장면의 혼합이나 패치 이식은 물리적으로 존재할 수 없는 도로 배치나 차량 궤적을 만들어낸다. 즉 재조합 기반 증강은 데이터셋 안에 이미 존재하는 도로 기하의 범위를 벗어나지 못하며, 회전교차로처럼 학습 데이터에 부재한 도로 기하는 원리적으로 합성할 수 없다. 이러한 이유로 본 연구는 재조합이 아닌 절차적 생성을 통해 회전교차로 도로 기하 자체를 새로 만들어내는 접근을 채택한다.

도로망 생성은 크게 실세계 데이터 기반(real-world data), 생성 신경망 기반(generative), 절차적 구성 생성(procedural constructive generation, PCG)의 세 가지로 구분된다. 실세계 데이터 기반 방법은 GIS·OSM·GPS 등 실측 데이터로부터 도로를 추출·복원하여 실세계의 복잡성과 다양성을 자연스럽게 포착하지만, 데이터 가용성에 의존하고 변형·확장이 어려워 학습 데이터 밖의 롱테일 시나리오를 확보하기 힘들다 [27]. 생성 신경망 기반 방법은 GAN 이나 확

산 모델(diffusion model)로 도로망 분포를 학습하여 사실적인 형태를 생성할 수 있으나, 학습 데이터 밖의 롱테일 영역에 대한 생성이 취약하고 차로 연결성(lane connectivity)의 일관성 확보가 어렵다 [28, 29].

이에 비해 절차적 구성 생성(PCG)은 알고리즘으로 도로를 절차적으로 생성하여 파라미터를 통해 결과를 정밀하게 제어할 수 있고, 학습 데이터 없이도 동작하므로 롱테일 환경에 적합하며, 대규모 변동성과 빠른 생성·재현성을 제공한다 [11, 30, 31]. 다만 회전교차로와 같은 복잡 구조를 지원하는 도구가 제한적이라는 한계가 있는데, 예를 들어 PGDrive는 4 지·90° 교차로만 생성할 수 있다 [31]. 본 연구는 회전교차로 절차적 생성을 지원하는 JunctionArt를 채택한다 [30]. 단, PCG로 다량 생성된 증강 데이터가 모두 학습에 유효한 것은 아니므로, 생성된 데이터의 적절성을 평가할 정량적 지표가 필요하다.

데이터 중심 성능 지표 측면에서, Dai 등은 증강 데이터의 풍부함(richness)과 편향(bias) 사이의 절충을 정량화하는 유효 정보 이득(effective information gain, EIG)을 제안하였다 [14]. EIG는 모델의 은닉 계층에서 산출되는 각 샘플의 특징 분포 부피인 매니폴드 부피(manifold volume)를 기반으로, 증강으로 인한 특징 공간의 풍부함 증가(richness gain)와 원본 분포로부터의 분포 이동(distribution shift)을 동시에 반영한다. 풍부함이 증가하면 모델이 더 다양한 패턴을 학습할 수 있지만, 원본 관측 분포로부터 과도하게 벗어나면 편향이 발생하여 성능이 저하될 수 있으므로, 두 요소의 균형을 나타내는 EIG는 증강 데이터의 유효성을 판단하는 정량 지표로 활용된다.

EIG 를 활용한 데이터 선별은 여러 EIG 수준의 증강 데이터셋으로 학습한 정확도 곡선에서 성능이 최대가 되는 목표 EIG 를 도출하고, 결합 EIG 가 목표값에 가장 가까워지는 부분집합을 순차적으로 누적하여 증강 데이터셋을 구성하며, 모델 구조 변경 없이 tail 에서 약 2.7~8.0 %p 의 성능 향상을 가져온다고 보고되었다 [14]. 한편 학습 데이터의 가치를 평가해 부분집합을 선택하는 coresets [36], 영향 함수 [37], Shapley 값 [38] 기반 연구는 주어진 학습 풀 내부에서 표본의 대표성이나 기여도를 평가하는 데 초점을 두는 반면, 본 연구의 문제는 분포 밖에서 새로 생성된 증강 데이터의 편입 여부와 편입량을 결정하는 것이므로 원본 분포 대비 풍부함과 분포 이동의 균형을 직접 정량화하는 EIG 가 적합하다. 따라서 본 연구는 절차적 도로 생성으로 부재한 회전 교차로 시나리오를 직접 증강하고 목표 EIG 기반 선별로 유효한 데이터만을 선택하여, 모델 구조 변경 없이 충돌 예측 모델의 롱테일 성능을 개선하는 방법을 제안한다.

1.3 문제 정의

충돌 예측은 주변 차량의 거동으로부터 충돌 위험을 사전에 감지하여 능동·수동 안전 시스템과 연계함으로써 충돌을 회피하거나 그 피해를 완화하는 것을 목적으로 한다. 이를 위해 충돌 시점 직전의 일정 구간을 프리크래시(pre-crash)로 정의하고, 모델은 이 구간에서 충돌 약 1.0~1.5 초 이전에 위험을 판단하면서도 안전한 정상 주행을 위험으로 오판하는 오정보(false positive,

FP)를 최소화하도록 설계되어야 한다. 본 연구가 대상으로 하는 CP-CNN은 주변 차량의 상태·예측값과 물리 기반 충돌 확률을 조감도 형태의 동적 의미지도(dynamic semantic map, DSM) 이미지로 추상화하여 입력으로 사용하므로 [21], 도로 기하는 모델의 외부 조건이 아니라 입력 영상 자체에 인코딩되는 핵심 요소이다. 본 절에서는 충돌 예측의 문제를 두 층위로 구분하여 정의한다. 하나는 충돌 예측 일반에서 오경보가 갖는 본질적 한계이고, 다른 하나는 본 연구가 직접 대상으로 하는 회전교차로 도로 기하에서의 오경보 문제이다.

먼저 일반적 층위에서, 충돌 예측에서 안전한 정상 주행 상황을 위협으로 오판하는 오경보는 불필요한 제동·경고를 유발하여 시스템의 신뢰성과 수용성을 직접 저해하므로, 이를 최소화하는 것이 핵심 설계 목표가 된다. 그러나 실 도로 주행 데이터는 대부분 안전한 정상 주행으로 구성되고 위험 상황이나 복잡한 도로 기하는 극히 드물게 나타나는 롱테일(long-tailed) 분포를 가지므로, 전체 데이터의 평균 오차를 최소화하도록 학습된 모델은 평균 성능이 높더라도 희소한 상황에서 오경보를 남긴다. 더욱이 오경보와 미검출(false negative)은 결정 임계값에 대해 상충 관계에 있어, 어느 한 알고리즘이나 학습 기법만으로 오경보를 완전히 0으로 만드는 것은 일반적으로 어렵다. 따라서 본 연구의 목표는 오경보의 완전한 제거가 아니라, 그 잔존 원인을 식별하고 가장 취약한 영역의 오경보를 체계적으로 저감하는 데 있다.

다음으로 구체적 층위에서, 본 연구가 대상으로 하는 충돌 예측 모델의 잔존 오경보가 어디에서 비롯되는지를 선행 연구의 분석 결과를 통해 살펴본

다. 충돌 예측 선행 연구 중 가장 우수한 성능을 보인 반복적 능동-커리큘럼 학습(iterative active-curriculum learning, ACL) 모델은 4 회 반복(iteration) 시 97.0 %의 최고 정확도를 달성하였다 [32]. 그러나 반복별 오경보를 원인(cause) 별로 분석하면, Figure 1-1 과 같이 능동 학습을 거듭할수록 대부분의 원인에 서 오경보가 감소하는 반면, 복잡한 도로 기하에서 기인하는 원인(분류 2-1) 의 오경보는 3 회차 2 건에서 4 회차 6 건으로 오히려 증가하였다. 능동 학습 은 모델이 오판단한 기존 데이터를 반복 재학습하는 방식이므로, 학습 풀 자 체에 해당 도로 기하가 부재한 한 풀 내부의 선별만으로는 이를 해소할 수 없 음을 시사한다. Table 1-1 은 능동 학습 반복에 따른 원인별 오경보 이벤트 수 를 정리한 것이다.




Figure 1-1. Accuracy and residual FP per active-learning iteration (AL, Seq. ACL, Iter. ACL)
(adapted from [32])

구분	Potential cause mode	Recommended action	Iter 1	Iter 2	Iter 3	Iter 4
1-1	Discrepancy between non-AI and AI model	Confidence	10	6	2	2
1-2	Instantaneous output error of AI component	Post-processing	3	1	1	1
2-1	Uncertainty of road geometry	Data augmentation	31	5	2	6
2-2	Uncertainty of multiple sensor measurements	Confidence	49	3	1	1
3	Others	-	25	1	0	0
Sum			118	16	6	10

Table 1-1. Residual FP analysis by cause mode across active-learning iterations (adapted from [32])

반복적 ACL 을 4 회 반복한 이후에도 도로 기하 인지 불확실성(분류 2-1)에서 기인한 오경보 6 건이 잔존하였으며, 이를 도로 기하별로 세분하면 도심로(urban road)에서 발생한 3 건과 회전교차로(roundabout)에서 발생한 3 건으로 나뉜다. 본 연구는 이 가운데 회전교차로에서 발생한 오경보 3 건을 직접 대상으로 한다. Figure 1-2 는 차선 신뢰도가 낮은 회전교차로에서 발생한 오경보 사례로, 모델이 원형 진입로의 곡선 기하를 학습한 적이 없어 정상 선회 거동을 충돌 임박으로 오판한 경우이다. 이는 일시적 센서 잡음이 아니라 학습 분포에 부재한 도로 기하에 대한 구조적 오판이며, 동일 기하를 학습 데이터에 공급하지 않는 한 반복적으로 재현된다.




Figure 1-2. Roundabout false-positive example under low lane-confidence of the vision sensor

이러한 회전교차로 상황이 잔존하는 근본 원인은 학습 데이터의 도로 유형별 분포에 있다. 여기서 head와 tail의 구분은 롱테일 인식 벤치마크에서 통용되는 표본 수 기준을 따라, 학습 표본이 많은 클래스를 head, 표본이 가장 적은 클래스를 tail로 정의한다 [14]. 본 연구는 도로 유형을 클래스로 보아 동일한 기준을 적용하였으며, Figure 1-3과 같이 충돌 예측 학습 데이터를 도로 유형 기준으로 집계하면 고속도로 유형이 20,845개로 가장 많아 head를 이루는 반면 회전교차로 유형은 9개로 가장 적어 극단적인 꼬리(tail)에 위치한다. 도로 유형별 클래스 분포의 불균형 정도(imbalance factor, IF)는 가장 빈번한 도로 유형의 표본 수($N_{\max}$)와 가장 희소한 도로 유형의 표본 수($N_{\min}$)의 비로 정의되며, 식 (1.1)과 같다.

$$IF = N_{\max} / N_{\min} \quad (1.1)$$

본 데이터셋에서 산출된 불균형도는 2,316 으로, 일반적인 롱테일 인식 벤치마크의 IF가 256 이하인 점을 크게 상회한다. 이는 도로 유형 관점의 롱테일이 통상적 수준을 훨씬 넘어, 풀 내부의 재학습이나 재가중만으로는 회전교차로 기하를 복원할 수 없는 수준임을 의미한다. 따라서 부재한 회전교차로 도로 기하를 학습 풀 외부에서 직접 확보하여 보강하는 접근이 불가피하다.




Figure 1-3. Road-type class distribution and the long-tail position of roundabouts

이상의 분석은 회전교차로 오경보가 학습 데이터에 부재한 도로 기하에서 비롯됨을 보여준다. 회전교차로 오경보를 겨냥한 가장 직접적인 증강은 오경보가 발생한 실제 회전교차로의 도로망을 위경도 정보로 동일하게 복원하고, 그 고정된 도로 기하 위에서 관측 거동 표본의 샘플링만을 결합하여 데이터를 생성하는 방법이다. 그러나 이는 관측된 특정 회전교차로 기하만을 재현할 뿐 도로 기하 자체의 다양성을 확보하지 못하므로, 회전교차로 오경보를

해소하기에 불충분하며, 이는 3장에서 정량적으로 확인된다. 또한 1.2절에서 논의한 바와 같이 재조합 기반 증강으로는 학습 데이터에 부재한 회전교차로 기하 자체를 확보할 수 없다. 반면 절차적 도로 생성은 이러한 부재 기하를 직접 만들어낼 수 있으나, 이렇게 생성된 분포 밖(out-of-distribution) 증강 데이터를 무분별하게 전부 학습에 사용하면 분포 이동(distribution shift)으로 오히려 성능이 저하된다. 따라서 본 연구에서는 다양한 회전교차로 기하를 직접 생성하는 절차적 도로 생성에 실제로 오경보에서 관측된 거동 표본의 샘플링을 결합하여 증강 데이터를 구축하고, 목표 유효 정보 이득(effective information gain, EIG) 기반의 정량적 선별로 학습에 유효한 데이터만을 선택하여, 모델 구조의 변경 없이 충돌 예측 모델의 롱테일 성능을 개선하는 방법을 제안한다. Figure 1-4는 제안 방법의 전체 프레임워크를 나타낸다.



Figure 1-4. Overall framework of the proposed roundabout augmentation and target-EIG selection

2. 충돌 예측을 위한 회전교차로 시나리오 생성

본 장에서는 회전교차로와 같은 복잡한 도로 기하 환경에서 발생하는 오경보를 저감하기 위해, 학습 분포 밖의 복잡한 도로 시나리오를 절차적으로 생성하여 증강 데이터를 구축하는 방법을 제안한다. 전체 절차는 HARA 와 SOTIF 의 triggering condition 분석을 결합하여 잔존 오경보의 원인을 분류하고 복잡한 도로 기하 데이터의 보강이 필요한 영역을 식별하는 단계에서 출발한다. 이후 PEGASUS 의 시나리오 추상화에 따라 절차적 도로 기하와 실도로 오경보에서 관측된 차량 파라미터 표본을 결합하여 concrete 시나리오 기반의 롱테일 증강 데이터셋을 구축하고, 다음 장에서 다룰 목표 EIG 기반 선별을 통해 추가 학습 데이터를 구성하여 충돌 예측 모델의 롱테일 상황을 개선한다 [9, 10].

2.1 학습 데이터 선정

본 절의 학습 데이터 구성과 능동 학습 절차는 선행 연구 [32]에서 구축된 자산을 본 논문의 전제로서 요약·기술한 것이며, 관련 표와 그림은 해당 문헌으로부터 인용·재구성하였다. 본 절에서 다루는 대상 모델은 주변 차량 정보를 조감도(bird's-eye view) 형태로 추상화하여 입력으로 받는 합성곱 신경망 기반 충돌 예측 모델(collision probability-convolution neural network, CP-CNN)이다 [21]. CP-CNN 은 자차량과 주변 차량의 상대 위치, 속도, 위험도를 동적

의미 지도(dynamic semantic map, DSM) 형태의 이미지로 변환하여 입력받고, 프리크래시 구간 동안 충돌 발생 여부와 충돌이 발생하는 부위인 충돌 모드(collision mode)를 예측한다. 이처럼 데이터로부터 패턴을 학습하는 모델은 학습 및 평가에 사용되는 데이터셋의 품질과 분포, 그리고 포함된 시나리오의 다양성에 의해 성능이 크게 좌우된다. 따라서 다양한 프리크래시 상황을 충분히 포괄하는 학습 데이터를 확보하는 것이 충돌 예측 모델의 성능을 결정하는 핵심 요소가 된다.

그러나 충돌을 포함하는 시계열 프리크래시 데이터는 공개된 형태로 거의 존재하지 않으며, 실제 도로에서 충돌 상황을 직접 수집하는 것은 안전상 불가능하다. 이러한 제약을 극복하기 위해 본 연구는 가상 시뮬레이션 데이터와 실도로 주행 데이터를 함께 사용한다. 시뮬레이션 데이터는 충돌을 포함한 다양한 시나리오를 정확한 정답(ground truth)과 함께 통제된 조건에서 대량으로 생성할 수 있다는 장점이 있다. 반면 실도로 주행 데이터는 센서 노이즈, 객체 인지 실패, 복잡한 도로 환경과 같이 시뮬레이션이 재현하기 어려운 현실적 요소를 포함하여, 오정보를 유발하는 실제 조건을 제공한다. 두 데이터를 함께 활용함으로써 충돌 시나리오에 대한 학습과 실도로 환경에 대한 강건한 평가를 동시에 달성할 수 있다.

실도로 주행 데이터는 다중 센서가 장착된 제네시스 G80(RG3) 차량 플랫폼을 이용하여 취득하였으며, 시뮬레이션 데이터는 IPG CarMaker를 이용하여 교통사고 통계 분석에 기반한 14개의 기본 시나리오로부터 약 13,000개의 상세(concrete) 시나리오 데이터를 생성한 것이다 [33, 34]. Table 2-1은 실

도로 및 시뮬레이션 데이터의 주행 시간과 거리를 정리한 것이며, Figure 2-1은 데이터 취득 플랫폼과 실도로 주행 경로를 보여준다.




Figure 2-1. Multi-sensor data acquisition platform and driving routes for the real-world dataset (adapted from [32])

종류	주행시간 (hr)	주행거리 (km)
Simulation (C2C)	68.08	3,717.5
FOT (RG3)	25.23	1,787.0
합계	93.31	5,504.5

Table 2-1. Summary of virtual-driving and real-driving data (adapted from [32])

Table 2-1 과 같이 시뮬레이션 데이터가 전체 주행량의 대부분을 차지하며, 상대적으로 양이 적은 실도로 주행 데이터(FOT)는 시뮬레이션이 담아내기 어려운 실제 센서 노이즈와 주행 복잡도를 포함하여 모델의 일반화 성능 평가에 핵심적인 역할을 한다.

Figure 2-1 의 실도로 취득 플랫폼은 전방 비전 센서와 전방·코너 레이더로 구성되며, 센서 융합(sensor fusion)으로 통합된 트랙을 조감도 형태의 DSM 으로 추상화하여 충돌 예측 모델의 입력으로 사용한다.

시뮬레이션 데이터를 생성하기 위해서는 시나리오, 파라미터, 도로에 대한 정의가 필요하다. 본 연구에서는 생성되는 데이터가 임의의 가정이 아니라 실제 사고가 빈번히 발생하는 상황 분포에 근거하도록, 사고 통계 분석을 통해 대표적인 프리크래시 시나리오를 선정하였다. 구체적으로 국내 교통사고 분석시스템(Traffic Accident Analysis System, TAAS)의 2012-2014 년 사고 통계 [33]와 유럽의 사고 데이터 표준화 사업(Initiative for the Global Harmonization of Accident Data, IGLAD) 통계 [34]를 함께 분석하였다. 그 결과 교차로(junction)와 비교차로(non-junction) 상황을 아우르는 차량 추종, 컷인, 선행 차량 컷아웃, 직진 교차 경로, 좌·우회전 경로 등 총 14 개의 기본 시나리오를 도출하였다.

선정한 각 기본 시나리오에 대해 자차량과 상대 차량의 속도, 거리, 진입 각도 등 파라미터의 범위를 정의한 뒤, 조합 수의 폭발적 증가를 피하면서도 주요 상호작용을 고르게 포함하도록 N-wise 샘플링을 적용하여 상세 시나리오를 생성하였다. 생성된 상세 시나리오는 IPG CarMaker 시뮬레이터에서 실행되어 프리크래시 구간의 DSM 시퀀스로 변환된다. 그 결과 14 개 기본 시나리오로부터 전체 12,786 개의 상세 시나리오가 구성되며, 시나리오별 상세 구성은 선행 연구 [32]를 참조한다.

상세 시나리오의 분포는 균일하지 않으나, 더 중요한 한계는 시나리오 단위의 양적 불균형이 아니다. 14 개 기본 시나리오는 차량 간 상호작용 유형을 기준으로 분류된 것으로 직선로와 단순 교차로 중심의 시뮬레이션 도로망 위

에서 생성되므로, 도로 기하(road geometry) 관점의 다양성이 본질적으로 부족하며 회전교차로와 같은 복잡한 도로 기하는 사실상 포함되지 않는다.

실제로 학습 데이터 풀에서 회전교차로 유형의 표본은 능동 학습 과정에서 추가되는 실도로 주행(FOT) 데이터에만 극소량 존재할 뿐이다. 그 결과 학습 데이터 풀은 도로 유형 관점에서 회전교차로가 극단적인 꼬리(tail)를 이루는 심한 롱테일 분포를 가지며, 이러한 부재는 풀 내부의 데이터 선별만으로는 해소할 수 없다. 따라서 부족한 회전교차로 도로 기하를 직접 생성하여 보강하는 접근이 필요하며, 이것이 뒤에서 다룰 절차적 도로 생성 기반 증강의 직접적인 동기가 된다.

확보한 데이터를 능동 학습(active learning)에 사용하기 위해서는 전체 데이터를 역할에 따라 분할해야 한다. 본 연구는 선행 연구 [32]를 따라 전체 데이터를 초기 학습(initial training) : 나머지(remaining) : 평가(test)를 1 : 1 : 2의 비율로 분할한다. 초기 학습 데이터는 기본 모델을 학습하는 데 사용되고, 나머지 데이터는 능동 학습 과정에서 추가할 샘플을 선별하는 풀(pool)로 활용되며, 평가 데이터는 모델의 성능을 측정하는 데 사용된다. 이때 데이터를 단순 무작위로 분할하면 특정 시나리오가 누락되거나 분할 간 분포가 달라질 수 있으므로, 14개 기본 시나리오의 비율이 각 분할에서 일정하게 유지되도록 시나리오 카탈로그를 기준으로 분할한다.

	Training		Test	Sum
	Initial	Remaining		
Simulation data (# of concrete)	3,177	3,253	6,356	12,786
Experimental data (# of snippet)	989	988	1,976	3,953
Sum	4,166	4,241	8,332	16,739

Table 2-2. Statistics of virtual and real-driving dataset split (adapted from [32])

Table 2-2 은 학습·평가 분할 통계를 정리한 것으로, 초기 학습 4,166 개, 나머지 4,241 개, 평가 8,332 개로 총 16,739 개의 데이터가 학습과 평가에 사용된다. 평가 데이터의 비중을 절반으로 크게 둔 것은 다양한 시나리오와 실도로 상황에서 모델의 일반화 성능을 충분히 검증하기 위함이다.

능동 학습 루프의 각 반복에서는 현재까지 학습된 모델로 나머지 데이터와 실도로 주행 데이터를 평가하여, 모델이 오판단한 샘플을 선별하고 이를 학습 데이터에 추가한 뒤 모델을 재학습한다. 일반적인 능동 학습은 예측 불확실성이 큰 샘플을 선택하지만, 충돌 예측에서는 오경보(false positive)를 최소화하는 것이 가장 중요하므로 오판단 샘플을 우선적으로 선별하는 전략이 효과적인 것으로 보고되었으며 [32], 본 연구도 이 방식을 따른다. 반복은 현재 단계의 성능이 더 이상 향상되지 않을 때까지 진행되며, 본 데이터셋에서는 4 회 반복($j = 4$)에서 수렴하였다.

이때 위험(unsafe) 샘플은 12 개 충돌 모드에 클래스당 2,000 개 상한을 적용하여 합계 24,000 개로 고정하고, 안전(safe) 샘플은 상한 없이 반복적으로 추가하여 오판단을 줄이는 방향으로 학습을 유도한다. 이러한 능동 학습 기반

의 점진적 데이터 확장은 모델이 오판단하기 쉬운 어려운 샘플을 우선적으로 학습에 반영하여 효율적인 성능 향상을 가능하게 한다.

Iteration	Training data	Unsafe (# of sample)	Safe (# of sample)	Sum (# of sample)
$j = 1$	$D_{tr}^1 = D^{ini}$	24,000	20,838	44,838
$j = 2$	Virtual	-	612	851
	Real	-	239	
	D_{tr}^2	24,000	21,689	45,689
$j = 3$	Virtual	-	1,249	1,325
	Real	-	76	
	D_{tr}^3	24,000	23,014	47,014
$j = 4$	Virtual	-	451	456
	Real	-	5	
	D_{tr}^4	24,000	23,470	47,470

Table 2-3. Number of training data across active-learning iterations (adapted from [32])

Table 2-3 와 같이 능동 학습이 반복될수록 선별된 안전 샘플이 추가되어 전체 학습 데이터는 44,838 개에서 47,470 개로 확대되며, 위험 샘플은 클래스 균형을 위해 전 구간에서 24,000 개로 유지된다. 추가되는 표본 수가 반복에 따라 감소하는 것은 모델의 오판단이 줄어 학습이 수렴하고 있음을 의미한다.

이상의 데이터 선정과 능동 학습은 주어진 학습 풀 안에서 모델의 성능을 효율적으로 향상시키지만 본질적인 한계를 가진다. 능동 학습은 이미 풀에 존재하는 데이터 중에서 학습에 유용한 샘플을 선별할 뿐이므로, 풀에 애초에 존재하지 않는 도로 유형의 데이터는 아무리 반복하여도 추가할 수 없다. 앞서 확인한 바와 같이 회전교차로와 같은 복잡한 도로 기하는 시뮬레이션과 실도로 데이터 모두에서 극히 희소하므로, 이러한 상황에서 발생하는 오정보

는 능동 학습만으로는 해소되지 않는다. 따라서 본 연구는 부족한 회전교차로 시나리오를 절차적으로 직접 생성하여 학습 데이터를 외부에서 보강하는 접근을 제안하며, 그 구체적인 방법은 다음 절들에서 다룬다.

2.2 충돌 예측 모델의 안전 분석

충돌을 포함하는 안전 직결 시스템에서는 단 한 번의 오판단도 치명적인 결과로 이어질 수 있으므로, 오경보가 발생하는 원인을 시스템의 구성 요소별로 체계적으로 분류하고 그 해결 방안을 제시할 필요가 있다. 본 연구에서는 FOT 데이터의 오경보를 ISO 21448 SOTIF의 triggering condition 분석으로 다섯 가지 잠재 원인(potential cause)으로 분류한다. 인공지능 모델이 포함된 충돌 예측 시스템은 센서 융합(sensor fusion), 인공지능 모델(CP-CNN), AI 후처리 등으로 구성되며, 각 구성 요소에서 발생하는 오판단의 원인을 구분하여 적합한 대응(recommended action)을 도출한다.

충돌 예측 시스템의 오경보 원인 분류는 다음의 순서도에 따라 단계적으로 이루어진다. 먼저 충돌 확률 $CP \geq 0.7$ 구간에서 물리 기반 위협 측정(threat measure)과 신경망(NN) 출력 간 불일치 여부를 판정한다. 두 판단이 일치하는 (모두 충돌로 판단하는) 오경보는 이중 한계(double threshold) 후처리($N_d = 3$, $\varepsilon = 0.6$)로 해소되면 AI 구성 요소의 순간적 출력 오류(분류 1-2)로, 해소되지 않으면 센서 융합 또는 위협 측정 추정에 기인한 오판(분류 1-1)으로 분류한다. 두 판단이 불일치하는 오경보는 비전 센서의 차로 인지 신뢰도(lane

confidence) 저하 여부와 센서 측정 여부를 차례로 판정한다. 각 범주의 명칭은 선행 연구 [32]의 분류 체계를 따르며, 판정 기준은 Figure 2-2의 순서도와 같다. 그 결과 잔존 오경보는 비-AI(물리 기반) 모델과 AI 모델 간 판단 불일치(분류 1-1), AI 구성 요소의 순간적 출력 오류(분류 1-2), 도로 기하의 불확실성(분류 2-1), 다중 센서 측정의 불확실성(분류 2-2), 그리고 기타(others, 분류 3)의 다섯 가지 원인으로 분류된다. Figure 2-2는 이러한 HARA/SOTIF 기반 오경보 분류의 순서도를 나타낸다.




Figure 2-2. HARA/SOTIF-based false-positive classification flowchart

이러한 분류 체계는 단순히 오경보를 나열하는 것을 넘어, 각 오경보가 시스템의 어느 구성 요소에서 비롯되는지와 그에 적합한 대응 전략

(recommended action)을 연결한다는 점에서 의의가 있다. Table 2-4 에 정리한 바와 같이, 비-AI(물리 기반) 모델과 AI 모델 간 불일치(분류 1-1)와 다중 센서 측정의 불확실성(분류 2-2)에서 기인하는 오경보는 센서 융합 및 측정의 신뢰도(confidence) 향상으로, AI 구성 요소의 순간적 출력 오류(분류 1-2)는 후처리(post-processing) 로직 보완으로 대응할 수 있다. 실제로 능동 학습을 4 회 반복한 시점에서 이들 원인의 잔존 오경보는 각각 2 건(분류 1-1), 1 건(분류 1-2), 1 건(분류 2-2)으로, 모델 및 후처리 수준에서 관리 가능한 수준에 머문다. 반면 도로 기하의 불확실성(분류 2-1)은 잔존 오경보가 6 건으로 가장 많으며, 모델이 학습한 도로 유형 분포 자체가 편향되어 발생하는 문제이므로 신뢰도나 후처리 보완으로는 근본적으로 해소되지 않고 데이터 보강(data augmentation)이라는 데이터 중심 대응이 요구된다.

구분	Potential cause mode	Possible classification	Recommended action	# of event (snippet)
1-1	Discrepancy between non-AI model and AI model	Both threat measure and NN predict collision (H/H); not resolved by double-threshold post-processing — due to sensor fusion or threat measure estimation (i.e., non-AI component)	Confidence	2
1-2	Instantaneous output error of AI component	Both threat measure and NN predict collision (H/H); resolved by double-threshold post-processing — due to collision prediction decision (i.e., post-processing component)	Post-processing	1
2-1	Uncertainty of road geometry	lane confidence of vision camera (low)	Data augmentation	6
2-2	Uncertainty of multiple sensor measurements	Due to sensor elements	Confidence	1
3	Others			0
Sum				10

Table 2-4. HARA/SOTIF-based false-positive cause classification and recommended actions

따라서 본 연구는 분류 2-1로 식별된 잔존 오경보 6건을 보장 대상으로 설정하며, 안전 분석으로 도출된 오경보 원인 분류가 이후 절차적 생성으로 보강할 시나리오의 출발점이 된다.


2.3 시나리오 선정

보장 대상으로 식별된 분류 2-1 오경보 6건의 도로 기하를 다시 세분하면, 도심로(urban road)에서 발생한 3건과 회전교차로(roundabout)에서 발생한 3건으로 나뉜다. 이러한 도로 기하별 잔존 오경보의 분포는 Figure 2-3의 막대 그래프에 함께 제시되며, 고속도로(HW)·교차로(INT)·기타(others)에서는 잔존 오경보가 발생하지 않고 도심로(URB)와 회전교차로(RAB)에 각각 3건씩 집중된다. 본 연구는 이 가운데 학습 데이터에서 가장 희소하면서 오경보가 집중되는 회전교차로 시나리오의 생성을 목표로 한다. 회전교차로 오경보는 충돌 예측 모델이 전방 충돌로 오인하는 시나리오와 후방 추돌로 오인하는 시나리오의 두 가지 논리 시나리오(logical scenario)로 정의된다. 이는 functional 수준에서 식별된 오경보 원인을 logical 수준으로 구체화하는 과정에 해당한다.


Figure 2-3는 두 논리 시나리오의 대표 사례를 보여준다. 전방 충돌 오인 시나리오는 자차량이 회전교차로를 따라 주행하는 중 상대 차량이 회전교차로에 진입하는 과정에서, 진입하는 상대 차량을 전방의 충돌 위험으로 과대평가하는 경우이다. 후방 추돌 오인 시나리오는 자차량이 곡률이 큰 회전교차

로의 바깥 차로를 따라 주행하는 중, 안쪽 차로의 상대 차량이 자차량보다 빠르게 접근하는 상대 거동을 보여 이를 충돌로 오인하는 경우이다. 이러한 논리 시나리오로부터 concrete 시나리오를 생성하기 위해서는, 정적 요소인 회전교차로 도로망(road network)과 동적 요소인 실도로 거동 기반 차량 파라미터(vehicle parameter)의 결합이 필요하다.






(a) 도로 기하별 잔존 오경보 분포



(b) 전방 충돌 오인 시나리오



(c) 후방 충돌 오인 시나리오

Figure 2-3. Residual road-geometry FP cases and the two logical scenarios ((a) 2-1 FP distribution by road type, (b) front, (c) rear-end)

2.4 도로망 생성

회전교차로 도로망은 JunctionArt 가 제시하는 3 단계 절차에 따라 4 지 회전 교차로로 절차적으로 생성한다 [30]. 첫째 단계(maximal circle)에서는 교차로 영역 내에 들어갈 수 있는 최대 원을 탐색하여 회전교차로의 기준 형상을 결정한다. 둘째 단계(circular road)에서는 이 기준 원을 따라 원형 도로를 생성하 되, Perlin noise 를 적용하여 반지름에 비원형(non-circular) 곡률을 부여한다. 셋째 단계(incident road)에서는 진입 도로를 연결하며, 진입점 위치는 $[-15^\circ, 15^\circ]$, 진입 방향(heading)은 $[-30^\circ, 30^\circ]$ 의 범위에서 변화시켜 다양한 진입 형상을 생성한다.

첫째 단계의 최대 원은 주어진 진입점 집합 $\{(x_i, y_i)\}$ ($i = 1, \dots, n$)에 대해 원 내부에 어떠한 진입점도 포함하지 않도록 결정된다. 먼저 원의 중심 (C_x, C_y) 은 진입점들에 대한 최소제곱 회귀 기반 원 적합(least-square regression circle fitting)으로 추정한다 [30]. 중심이 결정되면 반지름 r 은 중심에서 각 진입점 까지의 거리 중 최솟값에 비례 계수 0.4 를 곱하여 식 (2.1)과 같이 정한다. 여기서 1 미만의 비례 계수는 반지름 r 를 중심-진입점 최소 거리보다 작게 만들어, 중심 추정 방식과 무관하게 모든 진입점이 원 외부에 놓임을 보장하며, 0.4 라는 값은 원과 진입점 사이에 충분한 여유 거리를 확보하여 이어지는 단계에서 진입 도로를 무리한 곡률 없이 연결할 수 있도록 한 설계 선택이다 [30].

$$r = 0.4 \cdot \min_{i=1, \dots, n} \text{distance}((C_x, C_y), (x_i, y_i)) \quad (2.1)$$

본 연구의 데이터셋 생성에서는 링 크기를 통제하기 위해 기준 반지름을 11.2 m로 고정하였으며, 형상 다양성은 Perlin noise 왜곡으로 부여한다. 정리하면, 절차적 도로망 생성의 입력(input)은 진입점 위치 범위($[-15^\circ, 15^\circ]$), 진입 방향 범위($[-30^\circ, 30^\circ]$), Perlin noise, 기준 반지름(고정)의 네 가지이며, 기준 반지름을 제외한 입력을 변화시켜 출력(output)으로 변형된 1,000 개의 회전교차로 도로망을 생성한다. Figure 2-4는 maximal circle 탐색, circular road 생성, incident road 연결로 이어지는 절차적 생성의 3 단계와 그 결과를 나타낸다.




Figure 2-4. Procedural generation of complex roundabouts (3 steps)


이렇게 생성된 회전교차로 도로망의 다양성과 현실성은 Figure 2-5를 통해 정량적으로 분석할 수 있다. 구체적으로, 각 도로망의 링 중심선을 따라 0.5 m 간격으로 N 개의 샘플점을 추출하고, 그 무게중심 (c_x, c_y)(샘플점 좌표의 평균)

을 기준으로, k 번째 샘플점의 반지름 r_k 를 식 (2.2)와 같이 중심까지의 유클리드 거리로 산출하며, 인접한 두 샘플 간 반지름의 변화량 Δr_k 를 식 (2.3)과 같이 정의한다.


$$r_k = \sqrt{(x_k - c_x)^2 + (y_k - c_y)^2} \quad (2.2)$$

$$\Delta r_k = r_k - r_{k-1} \quad (2.3)$$


반지름의 분포는 폭넓게 나타나고, 정규화된 기준선(baseline)을 원 위에 중첩하면 형상이 다양하게 분포하여 도로망의 다양성을 보인다. 동시에 반지름 변화량의 분포는 0 근방에 집중되어 형상이 매끄럽게 변함으로써 현실성을 유지한다. 즉 Perlin noise 에 의한 비원형 곡률 덕분에 회전교차로의 형상이 다양해지면서도, 변화량이 완만하게 유지되어 물리적으로 비현실적이지 않은 회전교차로가 생성된다. 이러한 절차적 생성은 실세계 데이터에 존재하지 않는 회전교차로 도로 기하를 학습 데이터 없이도 대량으로, 그리고 제어 가능한 방식으로 확보할 수 있게 한다.



(a) Distribution of radii



(b) Distribution of the derivative of radii



(c) Normalized 4-way roundabouts superimposed on a circle

Figure 2-5. Diversity and realism analysis of the generated roundabout road networks: (a) radius length distribution and (b) radius change distribution for realism, and (c) normalized baseline overlay for diversity


앞서 정의한 반지름 r_k (식 (2.2))와 반지름 변화량 Δr_k (식 (2.3))를 이용하여, 절차적으로 생성된 도로망의 형상 다양성이 실제 오경보가 발생한 실측 회전교차로의 형상을 포함하는지를 정량적으로 비교한다. 다만 생성 도로망은 기준원 크기가 고정된 반면 실측 회전교차로는 평균 반지름이 서로 달라, 반지름을 원값 그대로 비교하면 크기 차이가 형상 비교를 왜곡한다. 이를 방지하

기 위해 각 도로망의 평균 반지름 $\bar{r} = (1/N) \sum_k r_k$ 로 나눈 스케일 불변(scale-invariant) 지표인 정규화 반지름 편차 $\tilde{x}_k$ 와 정규화 반지름 변화량 $\Delta\tilde{r}_k$ 를 식 (2.4)와 식 (2.5)와 같이 정의한다.


$$\tilde{x}_k = (r_k - \bar{r}) / \bar{r} \quad (2.4)$$

$$\Delta\tilde{r}_k = \Delta r_k / \bar{r} \quad (2.5)$$

여기서 $\tilde{x}_k = 0$ 은 해당 지점이 평균 반지름과 일치함(즉 완전한 원)을 의미하며, 양수와 음수는 각각 평균보다 바깥쪽과 안쪽으로의 형상 편차를 나타낸다. 도로별 평균 반지름 $\bar{r}$ 로 나누므로 링의 절대 크기는 제거되고 순수한 형상(비원형) 편차만 남는다. Figure 2-6은 생성 도로망(PCG roundabout, 1,000개 링의 전체 샘플)과 실측 오경보 회전교차로(FP roundabout, 2개)의 $\tilde{x}_k$ 분포(a)와 $\Delta\tilde{r}_k$ 분포(b)를 비교한 것이다. 이때 분포의 폭이 넓을수록 형상이 다양함을 의미하며, 막대의 높이는 다양성이 아니라 해당 구간에 집중된 표본의 비율을 나타낸다.



(a) Normalized radial deviation distribution



(b) Normalized radius change distribution

Figure 2-6. Normalized radial deviation (a) and radius change (b) distributions of PCG and FP roundabout road networks

두 지표 모두에서 실측 오경보 회전교차로의 분포는 생성 도로망 분포의 안쪽 좁은 구간에 놓인다. 정규화 반지름 편차(Figure 2-6(a))에서 실측 회전교차로는 약 $[-0.08, +0.09]$ 범위에 분포하여 생성 도로망 분포($[-0.41, +0.44]$)의 안쪽 부분집합에 위치하고, 정규화 반지름 변화량(Figure 2-6(b))에서도 실측은

약 $[-0.01, +0.01]$ 범위로 생성 분포($[-0.05, +0.03]$) 안쪽에 위치한다. 즉 절차적 생성은 실패가 발생한 실측 회전교차로의 형상을 포함하면서도 그 주변과 바깥의 형상까지 연속적으로 확장하여 채운다. 이러한 형상 다양성의 격차는, 고정된 실측 기하만을 사용하는 방식이 좁은 형상 영역만을 학습에 활용할 수 있어 일반화가 제한되는 반면, 제안하는 절차적 생성 기반 증강은 실패 형상을 포함한 넓은 형상 영역을 확보함으로써 회전교차로 잔존 오정보를 해소하는 기하학적 근거가 됨을 뒷받침한다. 다만 본 비교의 기준집합은 잔존 오정보 3 건이 발생한 실측 회전교차로 2 개소로, 생성 도로망이 이 형상들을 포함한다는 필요조건을 보이는 것이며 실세계 회전교차로 형상 전체를 대표하지는 않는다.

2.5 차량 파라미터 분포 추정 및 샘플링

절차적으로 생성된 정적 도로망에 동적 거동을 부여하기 위해, 실도로 오정보 데이터에서 관측된 차량 파라미터를 추출하여 샘플링한다. 입력으로는 앞서 도로 기하 인지 불확실성(분류 2-1)으로 식별된 회전교차로 오정보 3 건의 모든 프레임 값을 사용하였으며, 이 3 건은 동일 취득일의 2 개 회전교차로 구간에서 관측된 것으로, 전방 충돌 오인 2 건과 후방 충돌 오인 1 건으로 구성된다. 각 프레임에서 자차량 속도(v_{ego}), 상대 차량 속도(v_{target}), 상대 차량 가속도(a_{target})의 세 가지 파라미터를 추출하며, v_{ego} 는 차량 CAN 신호

에서 직접 취득하고 v_{target} 과 a_{target} 은 센서퓨전 트랙의 상대 속도·상대 가속도를 자차량의 속도·가속도에 합산하여 산출한다.

전방 충돌 오인 2 건에서 추출한 세 파라미터의 분포 특성은 파라미터별 1 차원 가우시안 혼합 모델(Gaussian mixture model, GMM)로 모형화하여 관측 거동의 다봉 구조를 확인한다. GMM 은 K 개의 가우시안 성분의 가중 합으로 분포를 표현하며, d 차원 단일 가우시안의 확률 밀도 함수는 식 (2.6)와 같고, 전체 혼합 분포는 식 (2.7)와 같이 정의된다.

$$N(x | \mu, \Sigma) = (2\pi)^{-d/2} |\Sigma|^{-1/2} \exp(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu)) \quad (2.6)$$

$$p(x) = \sum_{k=1}^K \pi_k N(x | \mu_k, \Sigma_k) \quad (2.7)$$

여기서 x 는 $(v_{\text{ego}}, v_{\text{target}}, a_{\text{target}})$ 의 각 파라미터 값, d 는 파라미터 차원 (본 연구에서는 파라미터별 1 차원 추정므로 $d = 1$), K 는 가우시안 성분의 수이고, 각 성분은 혼합 가중치 π , 평균 벡터 μ , 공분산 행렬 Σ 로 정의되며 가중치의 합은 1 이다. 본 연구의 파라미터별 1 차원 추정($d = 1$)에서는 평균 벡터와 공분산 행렬이 각각 스칼라 평균 μ 와 스칼라 분산 σ^2 로 축약되어, 식 (2.6)~(2.7)의 일반형은 1 차원 특수형으로 적용된다. 이 파라미터들은 기댓값 최대화(expectation-maximization, EM) 알고리즘으로 우도를 최대화하여 추정한다. 가우시안 성분 수 K 는 베이시안 정보 기준(Bayesian information criterion, BIC)을 최소화하는 값을 $K = 1 \sim 5$ 범위에서 탐색하여 파라미터별로 선택하였으며, 그 결과 v_{ego} 와 v_{target} 에 대해 $K = 4$, a_{target} 에 대해 $K = 2$ 가 선택되었다(Figure 2-7). 최종 파라미터 표본은 시나리오 제약($v_{\text{target}} \geq 10$ km/h, $v_{\text{ego}} > v_{\text{target}}$)을 만족하는 관측 프레임의 경험분포로부터 행 단위 복원추

출로 1,000 개를 샘플링하여, 절차적으로 생성된 1,000 개의 회전교차로 도로망에 1:1 로 배정한다. 행 단위 샘플링은 각 프레임의 (v_{ego} , v_{target} , a_{target}) 결합 구조를 그대로 보존하므로 파라미터 간 상관성이 유지된다. 이 설계에서 거동의 현실성은 관측된 실측 표본이 담당하고, 시나리오 다양성은 절차적으로 생성된 도로 기하가 담당한다. 다만 샘플링된 거동 표본은 해당 취득 조건에 조건부라는 한계를 가진다.

반면 후방 추돌 오인 1 건은 추출된 세 파라미터가 모든 프레임에서 사실상 동일한 값으로 나타나, 별도의 분포 추정 없이 단일 파라미터 집합으로 고정된다. 따라서 후방 추돌 오인 시나리오의 다양성은 파라미터 샘플링이 아니라, 절차적으로 생성된 서로 다른 회전교차로 도로망과 결합될 때에만 확보된다.

구성된 최종 표본이 관측된 전체 거동을 어떻게 대표하는지 확인하기 위해, 제약 적용 전 전체 관측 표본(153 프레임)과 최종 표본(1,000 개)의 분포 유사도를 Hellinger distance 로 측정한다(식 (2.8)). Hellinger distance 는 0(완전 일치)에서 1(불일치) 사이의 값을 갖는 유계·대칭 지표로 값의 직관적 해석이 가능하며, 상한이 없고 비대칭인 Kullback-Leibler divergence 에 비해 표본 수가 제한된 본 연구에서 재현 충실도를 안정적으로 정량화하는 데 적합하다.

$$H(p, q) = \sqrt{\frac{1}{2} \int (\sqrt{p(x)} - \sqrt{q(x)})^2 dx} \quad (2.8)$$

Hellinger distance 는 파라미터별로 전체 관측 표본과 최종 표본의 공통 구간을 30 개 동일 폭 빈(bin)으로 이산화하고 각 빈의 확률 질량 벡터 p, q 를 정규화한 뒤 식 (2.8)의 이산형 $H(p, q) = (1/\sqrt{2}) \|\sqrt{p} - \sqrt{q}\|_2$ 로 산출하였다. 빈 수 30

은 표본 규모(153 개 프레임)에서 분포의 다봉성 해상도와 빈당 기대 표본 수의 절충으로 선택하였으며, 히스토그램 기반 지표는 이산화 조건에 의존하므로 본 수치는 절대 유사도가 아니라 동일 조건 하 세 파라미터 간 상대 비교로 해석한다. 측정 결과 자차량 속도, 상대 차량 속도, 상대 차량 가속도의 Hellinger distance 는 각각 0.36, 0.33, 0.14 였다. 이 값은 시나리오 제약 적용 전의 전체 관측 표본과의 비교이므로, 제약에 의한 분포 절단이 반영된 수치이다.




Figure 2-7. Parameter distributions of FOT-FP data and fitted GMMs

정적 도로망과 동적 차량 파라미터를 결합하여 concrete 시나리오를 완성한다. 두 종류의 논리 시나리오 각각에 대해 1,000 개의 회전교차로-파라미터 쌍을 결합하여 총 2,000 개의 concrete 시나리오를 생성하고, 이를 CarMaker 시뮬레이터로 실행하여 롱테일 증강 데이터셋을 구축한다. 다만 생성된 2,000 개의 데이터가 모두 학습에 유효한 것은 아니므로, 다음 장에서 제안하는 목표 EIG 기반의 정량적 선별을 통해 유효한 증강 데이터를 선별한다.

3. 목표 EIG 기반 증강 데이터 선별

본 장에서는 앞 장에서 절차적으로 생성한 증강 데이터에 대하여, 모델 구조의 변형 없이 학습 데이터의 보강만으로 롱테일 도로 유형 중 회전교차로 상황을 개선하기 위한 목표 유효 정보 이득(target effective information gain, EIG) 기반의 정량적 선별 방법론을 제안한다. 1.3 절에서 논의한 바와 같이 분포 밖 증강 데이터의 무분별한 사용은 분포 이동에 의한 성능 저하를 유발하므로, 증강 데이터가 원본 분포에 더하는 정보의 풍부함(richness)과 분포 이동 사이의 균형을 정량화하는 지표인 EIG 를 도입하고, 결합 EIG 가 목표값에 수렴하도록 부분집합을 선별하여 추가 학습 데이터를 구성한다 [14]. 3.1 절에서는 EIG 의 정의를, 3.2 절에서는 증강 데이터의 군집화 기반 분류를, 3.3 절에서는 목표 EIG 에 수렴하는 부분집합 선별 절차를, 3.4 절에서는 제안 방법의 검증 및 평가 결과를 제시한다.

3.1 Effective Information Gain

유효 정보 이득(EIG)은 증강 데이터가 원본 데이터 분포에 더해질 때, 학습에 유익한 정보의 풍부함이 증가하는 정도와 분포가 원본으로부터 벗어나는 정도를 동시에 고려하여 증강의 실효성을 정량화하는 데이터 중심 성능 지표이다 [14]. 본 연구는 합성곱 신경망(CP-CNN)의 은닉 계층(hidden layer)으로부터 각 샘플의 특징 임베딩을 추출하고, 이 임베딩 공간에서 정의되는 매니

폴드 부피(manifold volume)를 기반으로 EIG 를 산출한다. 데이터 증강 방법을 A, 원본 데이터의 임베딩을 Z, 증강 데이터의 임베딩을 Z', 그리고 원본과 증강 데이터를 결합한 임베딩을 $F = [Z, Z']$ 라 할 때, 매니폴드 부피는 임베딩이 특징 공간에서 펼치는 부분공간의 크기를 나타내며, 수치적 안정성을 위해 공분산 행렬의 로그-행렬식(log-determinant)을 이용하여 식 (3.1)과 같이 정의한다.

$$V(X) = \frac{1}{2} \log_2 \det(I + (1/N) \bar{X} \bar{X}^T), \quad \bar{X} = X - \mu \mathbf{1}^T \quad (3.1)$$

여기서 X는 d 차원 임베딩 N 개로 이루어진 표본 집합, $\bar{X}$ 는 각 임베딩에서 평균 벡터 μ 를 뺀 평균 중심화(mean-centered) 행렬, I 는 항등 행렬이며, $(1/N) \bar{X} \bar{X}^T$ 는 임베딩의 공분산 행렬이다. 항등 행렬을 더하는 것은 공분산이 비정칙(non-full-rank)일 때 부피가 0 으로 소멸함을 방지하기 위함이고, 본 정의는 부호화율(coding rate) 계열의 부피 척도에 평균 정규화를 적용한 형태이다 [14]. 공분산의 고윳값을 λ_j 라 하면 식 (3.1)은 $V(X) = \frac{1}{2} \sum_j \log_2(1 + \lambda_j)$ 로 전개되어 각 주축 분산에 단조 증가하므로, V(X)가 클수록 해당 집합이 특징 공간에서 더 넓은 영역을 포괄함을 의미한다. 본 논문에서 '매니폴드 부피'는 기하학적 부피가 아니라 이 로그-행렬식 척도 V(X)를 지칭하는 조작적(operational) 용어이며, EIG 의 절대 수치는 부피 정의와 임베딩 구성에 의존하므로 모든 산출에 동일 정의를 일관 적용하였다. EIG 산출의 기준 임베딩 Z는 전체 학습 데이터가 아니라 증강 대상 클래스인 회전교차로 도로 유형의 학습 표본 임베딩(9 개)으로 정의하며, 이는 tail 클래스의 매니폴드를 기준으로 풍부함과 분포 이동을 측정하는 per-class 산출 방식을 따른 것이다 [14].

이때 기준 표본 수(9 개)가 축소 차원($d = 2,000$)보다 훨씬 작아 공분산이 비정칙이 되므로 식 (3.1)의 항등 행렬 정칙화는 이 부피가 잘 정의되기 위한 필수 조건이며, 차원 축소의 사영 기저는 3.2 절과 같이 전체 학습 데이터로부터 학습하여 클래스 기준 부피가 전체 분산 구조가 보존된 공통 부분공간 위에서 산출되도록 한다. 식 (3.1)을 Z 와 결합 임베딩 $F = [Z, Z']$ 에 각각 적용하여 $V(Z)$ 와 $V(F)$ 를 구하고, EIG 는 이 두 부피로 식 (3.2)와 같이 정의된다.

$$EIG(A, F, Z) = (V(F) - V(Z)) / V(Z) \quad (3.2)$$

식 (3.2)는 증강 데이터를 더해 결합 임베딩 F 를 구성했을 때 매니폴드 부피가 원본 대비 증가하는 비율로 EIG 를 정의한다. 결합 부피 $V(F)$ 는 Z 와 Z' 의 개별 부피의 단순 합이 아니라 두 집합이 함께 펼치는 부분공간의 부피로 계산되므로, 증강이 더하는 풍부함 이득(richness gain)과 원본 분포로부터의 분포 이동(distribution shift)이 하나의 비율에 동시에 반영된다. 이때 $V(Z)$ 는 고정이므로 EIG 는 $V(F)$ 에 대해 단조 증가하며, 학습에 유익한 풍부함 증가와 유해한 분포 이동이 모두 $V(F)$ 를 키워 EIG 를 증가시킨다. 즉 EIG 는 두 요소가 하나의 스칼라에 혼합되어 반영된 단조 지표로서 그 값이 클수록 좋은 지표가 아니며, 학습 성능은 EIG 에 대해 비단조(역 U자) 관계를 보여 풍부함과 편향이 균형을 이루는 특정 목표 EIG 에서 최대가 된다 [14]. 실제로 EIG 가 목표값을 초과하도록 증강을 늘리면 편향 누적으로 학습 성능이 저하되며, 이는 3.4 절의 무선별 전량 사용 조건(Case 5)에서 관측된다. 따라서 본 연구의 목적은 EIG 의 최대화가 아니라 결합 EIG 를 목표값에 수렴시키는 것이며, 목표값에 수렴하는 부분집합을 선별하여 증강 데이터를 구성한다.

3.2 증강 데이터 분류

EIG 기반 선별을 적용하기 위해서는 대량으로 생성된 증강 데이터를 EIG 계산이 가능한 부분집합(subset) 단위로 분류해야 한다. 본 연구는 2장에서 생성한 회전교차로 증강 데이터를 CP-CNN의 은닉 계층 임베딩으로 변환한 뒤, 차원 축소와 군집화를 통해 부분집합을 구성한다. 각 증강 샘플은 CP-CNN의 합성곱 은닉 계층을 통과하면서 다채널 특징 맵(feature map)으로 변환되며, 이 특징 맵의 모든 채널과 공간 위치($50 \times 25 \times 32$)를 1차원으로 펼치면(flatten) 40,000 차원의 고차원 임베딩 벡터가 된다. 두 max-pooling 계층은 패딩 없는 2×2 , stride 2 연산으로 홀수 크기 입력의 마지막 행·열이 절사되어, 공간 크기는 $201 \times 101 \rightarrow 100 \times 50 \rightarrow 50 \times 25$ 로 축소된다. 이러한 고차원 벡터는 직접적인 거리 기반 군집화에 적합하지 않으므로 주성분 분석(principal component analysis, PCA)을 적용하여 차원을 축소한다. PCA는 전체 학습 데이터의 임베딩 Z 에 대해 적합(fit)하며, 그 과정은 공분산 행렬 산출, 누적 분산 기반 차원 선택, 사영의 순서로 식 (3.3)~(3.5)와 같다.

$$C = (1/N) \sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T \quad (3.3)$$

$$d = \min \{ m : (\sum_{j=1}^m \lambda_j) / (\sum_{j=1}^D \lambda_j) \geq 0.95 \}, d \leq 2,000 \quad (3.4)$$

$$z_i = W_d^T (x_i - \mu) \quad (3.5)$$

여기서 x_i 는 i 번째 임베딩, μ 는 평균 벡터, N 은 표본 수, λ_j 는 공분산 C 의 j 번째 고유값, D 는 축소 전 차원, W_d 는 상위 d 개 고유벡터로 이루어진 사영 행렬이다. 식 (3.4)의 차원 선택은 $d = \min(\min\{m : \text{누적 분산 보존율} \geq 0.95\})$,

2,000), 즉 95% 기준을 만족하는 최소 차원과 상한 2,000 중 작은 값을 취하는 상한 절단(min-with-cap) 형태이다. 본 연구의 임베딩은 40,000 차원으로 2,000 개 주성분에서도 누적 분산 보존율이 81.67%에 그쳐 95% 기준에 도달하지 못하였으므로 상한에 걸려 $d=2,000$ 으로 결정되었으며, 이 과정에서 약 18.33%의 분산이 절단되는 한계가 있으나, 상위 2,000 개 주성분이 전체 분산의 81.67%를 보존하므로 거리 기반 군집화가 의존하는 지배적 분산 방향은 축소 공간에 유지된다. 사영 기저를 전체 학습 데이터 Z 로부터 학습하므로 축소된 부분공간은 원본 데이터의 분산 구조를 보존한다. Figure 3-1은 임베딩 추출과 차원 축소, 군집화로 이어지는 증강 데이터 분류 과정을 나타낸다.




Figure 3-1. Dimensionality reduction and clustering of augmented sample embeddings for subset construction

차원 축소된 증강 임베딩 Z' 에 대하여 k-means 군집화를 적용하여 전체 증강 데이터를 $K = 500$ 개의 부분집합으로 분할한다. k-means는 식 (3.6)과 같이 군집 내 제곱합(within-cluster sum of squares) J 를 최소화하는 군집 중심과 군집 할당을 반복적으로 갱신한다.

$$J = \sum_{i=1}^{N'} \sum_{k=1}^K r_{ik} \|z_i - c_k\|^2 \quad (3.6)$$

여기서 z_i 는 i 번째 증강 임베딩, c_k 는 군집 k 의 중심, r_{ik} 는 z_i 가 군집 k 에 속하면 1, 아니면 0 인 할당 변수이며, $K = 500$, N' 은 증강 임베딩의 수이다. 각 부분집합은 특징 공간에서 서로 인접한 증강 샘플들의 집합으로, 유사한 도로 기하 및 차량 파라미터 특성을 공유한다. 이렇게 구성된 500 개의 부분집합은 이후 목표 EIG 기반 선별 단계에서 결합 후보 단위로 사용되며, 각 부분집합을 학습 데이터에 추가했을 때의 결합 EIG 를 계산하여 선별 여부를 결정한다.

증강 데이터를 개별 샘플이 아닌 부분집합 단위로 다루는 까닭은 두 가지이다. 첫째, EIG 는 데이터 집합의 매니폴드 부피에 기반하므로 개별 샘플의 기여를 안정적으로 측정하기 어렵고 유사 특성을 공유하는 부분집합 단위에서 더 신뢰성 있게 산출되며, 둘째, 부분집합 단위 선별은 매 단계 결합 EIG 계산 횟수를 줄여 계산 효율을 높인다. 군집화와 선별의 단위는 시나리오가 아니라 학습 단위인 DSM 이미지(프레임)로, 생성된 concrete 시나리오를 시뮬레이터로 실행하여 얻은 DSM 프레임 중 계산 비용을 고려하여 무작위로 선별한 4,500 개를 $K = 500$ 개 부분집합으로 분할하면 부분집합당 평균 9 개 내외의 표본이 포함된다. 이는 매니폴드 부피 추정의 안정성을 확보하면서도 139 개 샘플 수준의 미세한 선별 해상도를 유지하는 규모이다. 군집 수 K 에 대한 민감도 분석은 K 값별 선별·재학습 반복의 계산 비용 제약으로 수행되지 않았으며, K 의 최적화는 목표 EIG 민감도 분석과 함께 향후 과제로 남긴다.

3.3 증강 데이터 선별

증강 데이터 선별의 목표는 대량의 부분집합 중 목표 EIG 를 만족하는 부분 집합의 결합(D_{aug})을 찾아 학습 데이터에 추가하는 것이다. 목표 EIG 의 설정을 위해, 선행 연구에서 불균형 정도를 나타내는 불균형 계수(imbalance factor, IF)가 100 을 초과하는 경우 최적 EIG 가 5.5 로 수렴함이 보고되었다 [14]. 본 연구의 충돌 예측 데이터셋은 회전교차로 도로 유형의 IF 가 2,316 으 로 롱테일 벤치마크의 $IF \leq 256$ 을 크게 상회하는 고불균형 상황에 해당하므로, 목표 EIG 를 5.5 로 설정한다. 본 데이터셋의 $IF = 2,316$ 은 최적 EIG 가 5.5 로 수렴한다고 보고된 고불균형 조건($IF > 100$)을 충족하므로, 5.5 의 채택은 문헌 조건 밖으로의 외삽이 아니라 보고된 수렴 조건 내에서의 적용이다. 또한 결과를 관찰한 뒤 목표값을 사후적으로 조정하는 선택 편향을 배제하기 위해, 문헌에 근거한 사전(a priori) 목표값을 고정한 상태에서 선별 절차를 검증하였다. 목표값별 민감도 스윙은 목표값 1 점당 전체 모델의 재학습 1 회를 요구하여 본 연구의 계산 자원 범위에서 수행하지 못하였으나, 본 실험 결과는 성능-EIG 의 역 U 자 관계 [14]와 정합하는 간접 증거를 제공한다. 즉 결합 EIG 가 목표값을 크게 초과하는 무선별 전량 사용(Case 5)에서 성능이 크게 저하되고 목표값에 수렴하는 선별(Case 10)에서 회복되는 대비는, 채택한 목표값 부근이 본 도메인에서도 유효한 동작 구간임을 지지한다. 다만 EIG 의 절대 수치는 임베딩 차원·표본 수·특징 추출기에 의존하므로 다중 클래스 영상 분류 벤치마크에서 도출된 5.5 가 본 도메인(조감도 기반 이진 충돌 예측)

의 최적 목표값임을 보장하지는 않으며, 이 경우 본 논문이 보고하는 성능 개선은 제안 절차가 달성할 수 있는 성능의 보수적 하한(lower bound)에 해당한다. 본 데이터셋 고유의 목표 EIG 민감도 분석을 통한 최적점 도출은 향후 과제로 남긴다.

선별 절차는 [14]의 Algorithm 2를 본 도메인의 클래스별(per-class) 설정에 맞추어 적용한 것으로, 알고리즘 1과 같다. 알고리즘의 입력(input)은 증강 방법 A, 학습 데이터 중 회전교차로 도로 유형 표본의 임베딩 Z, 목표 EIG 값 ($EIG_{target} = 5.5$), 3.2 절에서 군집화로 구성한 부분집합 집합 $S = \{S_1, S_2, \dots, S_n\}$, 그리고 허용 오차 ϵ 이며, 출력(output)은 결합 EIG가 목표값에 수렴한 증강 데이터셋 D_{aug} 이다. 알고리즘은 빈 집합($D_{aug} \leftarrow \emptyset$)에서 시작하여, 매 단계(process)마다 남은 부분집합 중, 기준 임베딩 Z와 현재까지 선별된 D_{aug} 의 결합에 추가했을 때의 결합 EIG를 목표 EIG에 가장 가깝게 만드는 부분집합 S_k 를 선택해 D_{aug} 에 누적하고 S에서 제거한다. 이 과정을 결합 EIG와 목표 EIG의 차이의 절댓값이 허용 오차 이하($|결합 EIG - 목표 EIG| \leq \epsilon$)가 되거나 부분집합이 소진될 때까지 반복하며, 본 연구에서는 허용 오차 ϵ 을 0.01로 설정하였다.

Algorithm 1. Subset combination algorithm for target EIG-augmented data (adapted from [14],
Algorithm 2)

Algorithm of Subset combination algorithm for target EIG-augmented data

Input: Data augmentation method (A), initial data D_{initial} , target EIG value ($\text{EIG}_{\text{target}}$), subsets $S = \{S_1, S_2, \dots, S_n\}$, and tolerance ε .

Output: Augmented dataset D_{aug} with EIG close to $\text{EIG}_{\text{target}}$

```

1: Initialize  $D_{\text{aug}} \leftarrow \emptyset$ 
2: Calculate initial EIG,  $\text{EIG}_{\text{current}} \leftarrow 0$ 
3: while  $|\text{EIG}_{\text{current}} - \text{EIG}_{\text{target}}| > \varepsilon$  do
4:   Find the subset  $S_k$  from  $S$  that minimizes  $|\text{EIG}(A, D_{\text{initial}} \cup D_{\text{aug}} \cup S_k) - \text{EIG}_{\text{target}}|$ 
5:   Update  $D_{\text{aug}} \leftarrow D_{\text{aug}} \cup S_k$ 
6:   Update  $\text{EIG}_{\text{current}} \leftarrow \text{EIG}(A, D_{\text{initial}} \cup D_{\text{aug}} \cup S_k)$ 
7:   Remove  $S_k$  from  $S$ 
8:   if  $S$  is empty then
9:     break {Terminate if no more subsets are available}
10:  end if
11: end while
12: if  $|\text{EIG}_{\text{current}} - \text{EIG}_{\text{target}}| \leq \varepsilon$  then
13:   return  $D_{\text{aug}}$ 
14: else
15:   Report that a suitable combination could not be found
16: end if

```




Figure 3-2. Cumulative combined EIG converging to the target value (5.5) as subsets are sequentially added in Algorithm 1 (PCG-FOT)

제안 절차를 본 연구의 증강 방법인 PCG-FOT(절차적 생성 + FOT 파라미터 샘플링)에 적용한 결과, 목표 EIG 5.5에 수렴하는 9개의 부분집합, 총 139개

의 샘플이 추가 학습 데이터로 선별되었다. Figure 3-2 는 부분집합을 하나씩 누적할 때 결합 EIG 가 목표값 5.5 로 수렴하여 9 개 부분집합에서 선별이 종료되는 과정을 보여준다. Table 3-1 은 선별된 증강 데이터셋 D_{aug} 의 구성을 능동 학습 4 회차(iter 4) 학습 데이터 D_{tr4} 와 비교하여 얼마나 추가되었는지 수치를 나타낸 것이다. D_{tr4} 의 unsafe·safe 샘플 수 24,000 / 23,470 개에 PCG-FOT 로 생성·선별된 가상 데이터 77 / 62 개가 추가되어, 최종 증강 학습 데이터셋 D_{aug} 는 unsafe 24,077 개, safe 23,532 개, 합계 47,609 개로 구성된다. 생성된 concrete 시나리오는 오경보를 재현하는 안전 시나리오를 목표로 설계되었으나, 샘플링된 거동 파라미터 조합에 따라 일부 시나리오에서는 시뮬레이션 상 실제 충돌이 발생하며, 해당 시나리오의 프리크래시 구간 프레임이 unsafe 로 라벨링되어 선별 데이터에 포함된다. 이에 따라 unsafe 표본 수가 24,000 개에서 24,077 개로 증가하는데, 이는 능동 학습에서 unsafe 를 24,000 개로 고정한 클래스 균형 프로토콜로부터 약 0.3% 수준의 이탈로, 클래스 비율에 미치는 영향은 미미하다.

Method	Training data	Unsafe (# of sample)	Safe (# of sample)	Sum (# of sample)
Active learning iter 4	D_{tr}^4	24,000	23,470	47,470
PCG-FOT	Virtual	77	62	139
	Real	—	—	—
	D_{aug}	24,077	23,532	47,609


Table 3-1. Composition of the target-EIG-selected augmented training dataset (D_{aug})

선별된 증강 데이터가 실제 오경보가 발생하는 상호작용 영역을 학습 분포에 집중적으로 채우는지를 확인하기 위해, 차량 간 상호작용 강도를 정량화하는 지표로 충돌점 도달시간차(modified time-to-conflict-point, $\Delta mTTCP$)를 사용한다 [35]. $\Delta mTTCP$ 는 충돌점을 도로 구조로 미리 지정하지 않고 두 차량이 실제 주행 경로에서 공유하는 모든 점을 충돌점 후보로 두어, 각 차량이 그 점에 도달하는 시간의 차이가 최소가 되는 값으로 정의된다. 값이 0에 가까울수록 두 차량이 충돌점에 거의 동시에 도달하는 임계(near-critical) 상호작용임을 의미한다. 충돌 예측 모델의 학습 단위가 DSM 이미지이고 증강 데이터의 선별 또한 이미지(프레임) 단위로 이루어지므로, 상호작용 지표는 시나리오 전체의 집계값이 아니라 각 이미지가 담고 있는 프레임 k 에서의 순간 값으로 식 (3.7)과 식 (3.8)과 같이 계산한다.


$$mTTCP_i^p(k) = d_i^p(k) / v_i(k) \quad (3.7)$$

$$\Delta mTTCP(k) = \min_{p \in CP} | mTTCP_{ego}^p(k) - mTTCP_{tgt}^p(k) | \quad (3.8)$$

여기서 $mTTCP_i^p(k)$ 는 프레임 k 에서 차량 i 가 자신의 실주행 경로를 따라 공유점 p 까지 남은 거리 $d_i^p(k)$ 를 그 순간 속도 $v_i(k)$ 로 나눈 값이며, CP 는 자 차량과 상대 차량의 실주행 경로가 공유하는 전방 충돌점 후보의 집합이다. Figure 3-3은 RAB 오경보 사례(a)와 전체 오경보(PSM+FOT)(b)를 기준으로, 생성 증강 후보 전체(PCG-FOT, no selection)와 EIG로 선별된 증강 데이터(PCG-FOT, EIG-selected)의 $\Delta mTTCP$ 분포를 비교한 것이다.



(a) Compared with RAB false positives



(b) Compared with all false positives

Figure 3-3. $\Delta mTTCP$ distributions of augmented training data compared with (a) RAB false positives and (b) all false positives

baseline 모델이 오경보를 낸 판단 프레임(FP decision frames)들은 $\Delta mTTCP$ 가 0에 가까운 저대역에 집중된다. 이는 오경보가 두 차량이 충돌점에 거의

동시에 도달하는, 아슬아슬하지만 실제로는 충돌에 이르지 않는 순간에 주로 발생함을 의미한다. EIG 선별 데이터는 임베딩만을 기준으로 선별되었음에도 바로 이 대역의 프레임 비율을 전체 후보 대비 약 5 배 높게(2.6%에서 13.2%로) 농축하여 포함한다. 즉 선별된 증강 데이터는 오경보가 실제로 발생하는 near-critical 상호작용 영역을 학습 분포에 집중적으로 채우며, 이는 회전교차로 및 전체 오경보의 감소와 정합하는 결과이다. 다만 이는 EIG 선별 분포가 오경보 대역에 농축된다는 경향을 보이는 것이며 통계적 검정을 주장하는 것은 아니다.

3.4 검증 및 평가

제안 방법의 효과를 검증하기 위해, 선별된 증강 데이터로 보강한 충돌 예측 모델의 성능을 평가 데이터셋에서 정량적으로 비교하였다. 성능 평가는 충돌 예측 분류 문제에서 널리 사용되는 정확도(accuracy), 오경보율(false positive rate, FPR), 미검지율(false negative rate, FNR), 그리고 판단 시점(decision time)의 네 가지 지표를 사용하였으며, 각 지표의 오판단 이벤트 개수를 함께 표기하였다. Table 3-2 는 평가 지표의 정의를 정리한 것이다. 여기서 t_1 은 충돌 1.5 초 이전 시점, t_2 는 충돌 시점을 의미한다. Figure 3-4 는 이러한 판단 시점(decision time)의 정의를 도식화한 것으로, 모델이 t_1 과 t_2 사이 구간에서 충돌을 예측하도록 설계되었음을 나타낸다. 본 논문의 FPR 은 safe 시나리오에서의 오경보와 pre-crash 시나리오에서의 t_1 이전 조기 판단을 합

산한 값으로, $[t_1, t_2]$ 구간 예측 프레임워크의 관례를 따른 정의이다. 두 성분의 분리 보고는 향후 과제로 남긴다.

Metric	Equation	Description
False Positive Rate (%)	$FPR = \frac{FP}{FP + TN}$	Safe 시나리오에서 충돌로 판단하거나, pre-crash 시나리오에서 t_1 이전에 충돌로 판단한 경우
False Negative Rate (%)	$FNR = \frac{FN}{TP + FN}$	$t_1 \sim t_2$ 구간에서 safe 로 판단한 경우
Accuracy (%)	$ACC = \frac{TP + TN}{TP + FP + FN + TN}$	모든 시나리오에서 알고리즘이 내린 올바른 결정의 비율
Decision time (s)	$\tau_c = t_2 - t_c$	알고리즘이 처음 충돌로 판단한 시점

Table 3-2. Evaluation metrics for collision prediction performance




Figure 3-4. Definition of decision time

성능 비교를 위한 증강 기법으로는 기존 재조합 기반 기법인 CMO 와 Remix, 실측 도로망 기반 기법인 Real road-FOT, 그리고 제안 기법인 PCG-FOT 를 함께 평가하였다. CMO 와 Remix 는 앞서 1.2 절에서 기술한 바와 같이 기존 샘플을 혼합·재조합하여 소수 클래스를 보강하는 대표적 데이터 증강 기법이다 [25, 26]. Real road-FOT 는 오경보가 발생한 실제 회전교차로 2 개소의 도로망을 위경도 정보로 복원한 뒤 그 고정된 도로 기하 위에서 제안 기법과 동일한 관측 거동 표본 샘플링을 결합하여 데이터를 생성하는 기법으로, 거동 생성 절차를 공유한 채 도로 기하 다양성 유무만이 달라 제안 기법(PCG-FOT)

의 핵심 비교군에 해당한다. PCG-FOT는 절차적으로 생성한 다양한 회전교차로 도로 기하에 동일한 관측 거동 표본 샘플링을 결합한 제안 증강 기법이다. 네 기법 모두 동일한 충돌 예측 모델과 학습 절차에서 평가하였으며, 각 증강 기법에 선별 없음과 EIG 선별의 두 조건을 적용하여 비교하였다. 제안 기법인 PCG-FOT에 한하여는 선별 품질의 효과를 표본량 축소의 효과와 분리하기 위해 동일 규모의 무작위 선별 조건을 대조군으로 추가하였다(3.4 절 후반의 통제 비교 참조). 이때 모든 실험 조건의 네트워크 구조 및 학습 하이퍼파라미터(옵티마이저, 학습률, 에폭, 손실 함수)는 기준 성능을 제공한 선행 연구 [32]와 동일하게 설정하였으며, 증강 데이터의 추가 외에는 학습 절차를 변경하지 않았다.

Table 3-3은 가상 주행 및 실도로 주행 데이터를 모두 포함하는 전체 평가 데이터셋에 대한 성능 비교 결과이다. 증강 방법 없음 1개 조건(Case 1), 네 가지 증강 방법(CMO·Remix·Real road-FOT·PCG-FOT)에 선별 없음·EIG 선별을 각각 적용한 8개 조건(Case 2~8), 그리고 PCG-FOT에 무작위 선별을 적용한 대조군 1개 조건(Case 9)으로 총 10개의 실험 조건을 구성하였다. 제안 기법인 PCG-FOT 생성과 목표 EIG 선별을 결합한 Case 10은 정확도 97.6%, FPR 2.31%로, 증강을 적용하지 않은 기준 모델(Case 1, 정확도 97.0% / FPR 3.65%) 대비 정확도와 오경보율이 모두 향상되었다. 반면 PCG-FOT 증강 데이터를 선별 없이 전부 학습에 사용한 Case 5는 FPR이 8.12%로 크게 저하되어, 분포 밖 증강 데이터의 무분별한 사용이 성능을 저하시킴을 확인할 수 있다. 동일

하게 EIG 선별을 적용한 기존 증강 기법(CMO·Remix)과 비교해도 제안 기법이 정확도와 오경보율 모두에서 가장 우수한 결과를 보였다.

Case	Augmentation	Selection	Acc↑ (%)	FNR↓ (%)	FPR↓ (%)	판단시점↑ (s)
1 (original)	None	No selection	97.0	1.66 (43)	3.65 (204)	0.915
2	CMO	No selection	97.3	2.61 (68)	2.68 (150)	0.903
3	Remix	No selection	97.3	1.70 (44)	3.23 (181)	0.906
4	Real road-FOT	No selection	97.0	2.19 (57)	3.30 (184)	0.906
5	PCG-FOT	No selection	93.9	1.86 (48)	8.12 (455)	0.931
6	CMO	EIG	96.1	1.96 (51)	4.74 (265)	0.925
7	Remix	EIG	97.4	2.07 (54)	2.90 (162)	0.900
8	Real road-FOT	EIG	96.9	2.05 (53)	3.61 (202)	0.918
9	PCG-FOT	random	95.8	1.82 (47)	5.25 (296)	0.924
10 (proposed)	PCG-FOT	EIG	97.6	2.62 (68)	2.31 (129)	0.916

Table 3-3. Collision prediction performance on all data (virtual-driving + real-driving)

Case	Augmentation	Selection	Acc↑ (%)	FNR↓ (%)	FPR↓ (%)	판단시점↑ (s)
1 (original)	None	No selection	96.2	1.6 (43)	5.1 (194)	0.931
2	CMO	No selection	96.7	2.62 (68)	3.78 (142)	0.903
3	Remix	No selection	96.5	1.70 (44)	4.69 (177)	0.906
4	Real road-FOT	No selection	96.3	2.19 (57)	4.79 (180)	0.906
5	PCG-FOT	No selection	93.1	1.86 (48)	10.4 (392)	0.931
6	CMO	EIG	95.2	1.97 (51)	6.77 (255)	0.925
7	Remix	EIG	96.7	2.08 (54)	4.21 (158)	0.900
8	Real road-FOT	EIG	96.1	2.05 (53)	5.23 (197)	0.918
9	PCG-FOT	Random	95.7	1.82 (47)	5.93 (224)	0.924
10 (proposed)	PCG-FOT	EIG	96.9	2.62 (68)	3.35 (126)	0.916

Table 3-4. Collision prediction performance on virtual-driving data

Case	Augmentation	Selection	Acc↑ (%)	FPR↓ (%)
1 (original)	None	No selection	99.4	0.5 (10)
2	CMO	No selection	99.6	0.44 (8)
3	Remix	No selection	99.7	0.22 (4)
4	Real road-FOT	No selection	99.7	0.22 (4)
5	PCG-FOT	No selection	96.6	3.45 (63)
6	CMO	EIG	99.4	0.55 (10)
7	Remix	EIG	99.7	0.22 (4)
8	Real road-FOT	EIG	99.7	0.27 (5)
9	PCG-FOT	Random	96.1	3.87 (72)
10 (proposed)	PCG-FOT	EIG	99.8	0.16 (3)

Table 3-5. Collision prediction performance on real-driving data

Table 3-4 와 Table 3-5 는 각각 가상 주행 데이터와 실도로 주행 데이터로 구분한 성능 평가 결과이다. 가상 주행 데이터에서 제안 기법(Case 10)은 정확도 96.9%, FPR 3.35%를 기록하여 기준 모델(Case 1, 정확도 96.2% / FPR 5.1%) 대비 향상되었으며, 실도로 주행 데이터에서는 정확도 99.8%, FPR 0.16%(3건)로 모든 조건 중 가장 낮은 오경보율을 달성하였다.

한편 제안 기법(Case 10)의 FNR 은 2.62%(68 건)로 기준 모델(1.66%, 43 건) 대비 증가하였다. 이 트레이드오프의 규모를 오판단 이벤트 수로 정량화하면, 오경보는 204 건에서 129 건으로 75 건 감소한 반면 미검출은 25 건 증가하여, 전체 오판단은 247 건에서 197 건으로 50 건(20.2%) 순감소하였으며 이는 정확도 향상(97.0%→97.6%)과 정합한다. 이러한 FNR 증가는 1.3 절에서

사전에 정의한 오경보-미검출의 결정 임계값에 대한 상충 관계가 데이터 증강 관점에서 나타난 것으로, safe 방향의 증강 데이터 추가가 결정 경계를 보수적으로 이동시킨 결과이며, 본 연구의 문제 정의인 도로 기하 인지 불확실성(분류 2-1) 기인 오경보의 표적 저감이라는 목표 범위에 부합한다. 실제로 FNR 증가는 제안 기법에 국한된 현상이 아니라 CMO(2.61%) 등 safe 표본을 보장하는 증강 기법 전반에서 공통적으로 관찰되며, 제안 기법의 FNR은 이들과 동등한 수준이다. 또한 판단 시점은 0.915 초에서 0.916 초로 유지되어, 충돌로 검출된 사례에 대한 예측 적시성의 손실은 없었다. 다만 미검출은 오경보와 안전 위해도의 성격이 다르므로 이벤트 수의 산술 비교만으로 안전상 등가 교환을 주장할 수는 없으며, 미검출 증가분 각각에 대한 잔여 회피 시간 기준의 위해도 정량 분석과 응용 요구사항에 따른 오경보-미검출 균형의 재설계는 향후 과제이다.

한편 EIG 선별의 효과는 증강 기법의 특성에 따라 상이하게 나타난다. Remix는 EIG 선별 적용 시 FPR이 3.23%에서 2.90%로 개선된 반면(Case 3 대 Case 7), CMO는 선별 적용 시 정확도가 97.3%에서 96.1%로 오히려 저하되었다(Case 2 대 Case 6). 이러한 차이는 EIG 선별이 은닉 계층 임베딩 공간의 매니폴드 부피에 기반한다는 점에서 설명될 수 있다. 1.2 절에서 논의한 바와 같이 CMO는 서로 다른 장면의 전경 패치를 이식하여 도로 기하와 차량 거동의 물리적 일관성이 결여된 합성 이미지를 생성하므로, 그 임베딩은 실제 주행 장면이 이루는 매니폴드에서 벗어난 영역에 산재하게 되고, 이러한 임베딩 위에서 산출되는 결합 EIG는 풍부함과 분포 이동의 균형을 왜곡되게 반영할

수 있다. 즉 Case 6의 성능 저하는 EIG 선별 절차 자체의 한계라기보다, 물리적 일관성이 결여된 재조합 증강과 임베딩 기반 선별 간의 부정합에서 비롯된 것으로 해석되며, 이는 장면 단위 조감도 입력을 사용하는 충돌 예측 도메인에서 재조합 기반 증강이 갖는 구조적 부적합성을 선별 단계에서 재확인하는 결과이다. 반면 시뮬레이터에서 물리적으로 일관되게 생성된 PCG-FOT 증강 데이터는 임베딩이 원본 매니폴드와 연속적인 관계를 유지하므로 EIG 선별이 의도대로 동작하며, 절차적 생성과 목표 EIG 선별의 결합이 유효한 것은 이러한 정합성에 기인한다.

본 절의 성능 수치는 기준 성능을 제공한 선행 연구 [32] 및 비교 증강 기법의 원 연구 [25, 26]와 동일하게 단일 학습 실행 기준으로 보고하며, 이는 본 도메인 응용 연구의 통상적 보고 방식과 일치한다. 아울러 본 논문의 핵심 결론은 실행 간 분산에 민감한 소수점 단위의 개선폭이 아니라, 무선별 전량 사용 대비 목표 EIG 선별의 큰 폭의 성능 대비(FPR 8.12% 대 2.31%)와 목표 오경보의 표적 저감(회전교차로 FP 3 건→0 건)에 기반한다. 실제로 오경보는 이벤트 수가 적으므로 포아송 95% 신뢰구간을 병기하면 기준 10 건은 [4.8, 18.4], 제안 3 건은 [0.6, 8.8]로 구간이 일부 겹치며, 이에 따라 소표본 이벤트에 기반한 결과는 경향성의 제시로 해석한다.

마지막으로, 제안 기법이 본래 목표로 한 회전교차로 도로 기하 오경보의 저감 효과를 검증하기 위하여, 실제로 주행 데이터의 잔존 오경보를 HARA/SOTIF 기반 잠재 원인별로 분류하여 비교하였다. Table 3-6은 능동 학습 반복(iter 1~4)에 따른 원인별 오경보 추이와, CMO(전체 사용)·Remix(EIG

선별)·Real road-FOT(전체 사용)·PCG-FOT(EIG 선별)를 적용했을 때의 원인 별 오경보 개수를 정리한 것이다. 증강 데이터를 추가하여 학습한 제안 모델은 기준 대비 전체 실도로 오경보를 10 건에서 3 건으로 70% 저감시켜 CMO(8 건)·Remix(4 건)·Real road-FOT(4 건) 대비 최소 오경보를 달성하였다. 특히 본 연구의 목표인 도로 기하 인지 불확실성(2-1) 오경보는 1 건으로 최소화되었으며, 그중 회전교차로에서 기인한 오경보는 평가 데이터 기준 3 건에서 0 건으로 감소하였다. Figure 3-5는 도로 기하 인지 불확실성에 의한 오경보의 분포를 방법별로 시각화한 것으로, 제안 기법에서 회전교차로 기인 오경보가 관측되지 않았음을 보여준다. 한편 Table 3-6의 방법별 선별 설정(CMO: 전체 사용, Remix: EIG 선별, Real road-FOT: 전체 사용)은 각 증강 기법에 대해 예비 실험에서 가장 우수한 성능을 보인 설정을 제시한 것으로, 경쟁 기법에 유리한 설정을 허용한 보수적 비교 원칙에 따른 것이다.

구분	Potential cause mode	Iter 1	Iter 2	Iter 3	Iter 4	CMO (All)	Remix (EIG)	Real road-FOT(All)	PCG-FOT (EIG)
1-1	Discrepancy (non-AI vs AI)	10	6	2	2	1	2	0	2
1-2	AI output error (post-proc.)	3	1	1	1	1	0	0	0
2-1	Road geometry uncertainty	31	5	2	6	6	2	2	1
2-2	Multi-sensor uncertainty	49	3	1	1	0	0	1	0
3	Others	25	1	0	0	0	0	1	0
Sum		118	16	6	10	8	4	4	3

Table 3-6. HARA/SOTIF-based false-positive classification on real-driving data across methods (each augmentation method shown with its best-performing selection setting)




Figure 3-5. Road geometry uncertainty false-positive distribution (each augmentation method shown with its best-performing selection setting)

이상의 결과는 절차적 생성으로 구축한 회전교차로 증강 데이터를 목표 EIG 기반으로 정량 선별하여 학습에 보강함으로써, 모델 구조의 변형 없이도 복잡한 도로 기하 환경에서의 오경보를 효과적으로 저감할 수 있음을 보여준다. 특히 무선별 전량 사용(Case 5, FPR 8.12%)과 목표 EIG 수렴 선별(Case 10, FPR 2.31%)의 대비는, 증강 데이터의 양이 아니라 풍부함과 편향의 균형을 고려한 정량적 선별이 성능 향상의 관건임을 시사한다.

Case 5 와 Case 10 은 선별 방식과 표본 수(이미지 기준 전량 4,500 개 대 선별 139 개)가 동시에 달라 두 효과가 교락되므로, 이를 분리하기 위해 동일 규모(139 개)의 무작위 부분집합으로 학습한 Case 9 를 대조군으로 두었다. 전체 평가 데이터 기준 FPR 은 전량 사용 8.12%에서 무작위 선별 5.25%로 낮아진 뒤 목표 EIG 선별에서 2.31%에 도달하여, 전량 사용 대비 총 5.81%p 의 개선

가운데 표본량 축소에 기인하는 부분은 2.87%p 인 반면 동일 표본 수에서 선별 품질에 기인하는 부분이 2.94%p 로 절반 이상을 차지한다. 더욱이 무작위 선별(정확도 95.8%, FPR 5.25%)은 증강을 적용하지 않은 기준 모델(97.0%, 3.65%)보다도 열등하여, 표본량 축소만으로는 분포 밖 증강 데이터가 유발한 성능 저하를 회복하지 못한다. 이 대비는 실도로 주행 데이터에서 더욱 뚜렷하여, 무작위 선별의 FPR 은 3.87%(72 건)로 전량 사용(3.45%, 63 건)보다 오히려 높은 반면 목표 EIG 선별은 0.16%(3 건)를 달성하였다. 즉 본 연구의 성능 향상은 증강 데이터의 양을 줄인 결과가 아니라 목표 EIG 수렴을 기준으로 선별한 데이터의 품질에 기인함이 동일 규모 대조군과의 통제 비교로 확인된다.

또한 Figure 3-5 의 도로 유형별 오경보 분석은 제안 기법의 효과가 본 연구가 목표로 한 도로 기하 인지 불확실성(분류 2-1), 특히 회전교차로에 집중되어 나타남을 보여준다. 절차적으로 생성한 회전교차로 데이터를 보강한 PCG-FOT(EIG 선별) 모델은 분류 2-1 오경보를 1 건으로 최소화하고 회전교차로 기인 오경보를 3 건에서 0 건으로 저감하였다. 반면 오경보가 발생한 실제 회전교차로 도로망을 위경도 정보로 동일하게 복원하여 그 고정된 기하 위에서 동일한 거동 표본만 결합한 Real road-FOT 는 분류 2-1 오경보를 2 건으로 줄였으나 회전교차로 오경보를 1 건 남겨, 관측된 기하의 복원만으로는 회전교차로 오경보가 해소되지 않고 도로 기하 자체의 다양성이 필요함을 보인다. 재조합 기반 기법의 경우, CMO 는 분류 2-1 오경보를 기준과 동일한 6 건으로 유지하면서 회전교차로 오경보를 오히려 3 건에서 4 건으로 증가시켰

고, Remix 는 분류 2-1 을 2 건으로 줄이며 회전교차로 오경보를 0 건으로 해소하였다. 다만 Remix 는 도심로 기하의 오경보(2 건)와 전체 실도로 오경보(4 건)가 제안 기법(각각 1 건, 3 건)보다 많아, 제안 기법이 도로 기하 전반에서 가장 낮은 오경보와 FPR 을 달성하였다. 이는 관측된 기하의 단순 복원이 아니라 다양한 회전교차로 기하를 직접 생성·선별하는 절차적 접근이 가장 낮은 오경보를 달성함을 실증적으로 확인한 결과이다.

4. 결론

본 연구에서는 딥러닝 기반 차량 간 충돌 예측 모델이 회전교차로와 같은 복잡한 도로 기하 환경에서 보이는 롱테일 성능 한계를 개선하기 위하여, 절차적 도로 생성 기반의 데이터 증강과 목표 EIG 기반의 정량적 데이터 선별을 결합한 방법론을 제안하였다. 선행 연구의 능동-커리큘럼 학습으로 최고 성능을 달성한 모델에도 도로 기하 인지 불확실성(분류 2-1)에서 기인한 오경보가 잔존하였으며, 해당 회전교차로 도로 유형은 불균형 계수 2,316 의 극단적 롱테일로서 학습 풀 내 선별만으로는 해소되지 않음을 확인하였다. 이에 HARA 와 SOTIF triggering condition 분석으로 보강 대상 오경보를 식별한 뒤, JunctionArt 기반 절차적 회전교차로 생성에 실도로 오경보 데이터에서 관측된 거동 파라미터 표본을 결합하여 학습 데이터에 부재한 회전교차로 시나리오를 직접 생성하였고, 합성곱 신경망의 은닉 계층 임베딩과 k-means 군집화

로 부분집합을 구성한 뒤 결합 EIG 가 목표값에 수렴하도록 선별하여 학습 데이터에 보강하였다.

정량 평가 결과, 제안 기법(PCG-FOT 생성 + 목표 EIG 선별)은 기준 모델 대비 정확도를 97.0%에서 97.6%로 향상시키는 동시에 전체 실도로 오경보를 10 건에서 3 건으로 70% 저감하였으며(전체 평가 데이터 기준 FPR 3.65%→2.31%), 본 연구가 목표로 한 회전교차로 도로 기하 오경보는 평가 데이터 기준 3 건에서 0 건으로 감소하였다. 다만 이는 소표본의 실도로 오경보 이벤트에 한정된 결과로 외적 타당성은 추가 검증이 필요하며, Remix(EIG) 역시 회전교차로 오경보 0 건을 달성하였으므로 제안 기법의 차별성은 회전교차로 단독 결과가 아니라 도로 기하 다양성의 확보와 도로 기하 전반에 걸친 최저 총 오경보(3 건)·최저 FPR 의 동시 달성에 있다. 아울러 고정된 실측 기하만을 복원한 Real road-FOT 가 회전교차로 오경보를 해소하지 못한 3.4 절의 결과는, 관측된 기하의 단순 복원이 아닌 도로 기하 자체의 다양성 확보가 필요함을 뒷받침한다. 아울러 동일 규모(139 개)의 무작위 선별 대조군과의 통제 비교에서, 무작위 선별은 기준 모델보다 열등한 반면 목표 EIG 선별만이 개선을 달성하여 성능 향상이 증강 데이터의 양이 아니라 선별 품질에 기인함을 확인하였다.

본 연구의 고유 기여는 다음 세 가지로 요약된다. 첫째, JunctionArt 기반 절차적 회전교차로 생성과 실도로 오경보 데이터의 관측 거동 표본 샘플링을 결합한 룬테일 증강 파이프라인의 구축, 둘째, 목표 EIG 기반 정량 선별의 조감도 기반 이진 충돌 예측 도메인에의 적용, 셋째, HARA/SOTIF 기반 오경보

원인 분류와 데이터 중심 대응의 연계이다. 한편 대상 모델(CP-CNN [21]), 학습·평가 데이터셋과 능동 학습 파이프라인 및 기준 성능 [32], EIG 지표와 부분집합 결합 선별의 기본 구조 [14], 절차적 생성 도구 [30]는 선행 연구의 자산을 상속·활용한 것이다. 즉 본 연구의 신규성은 새로운 요소 기술의 발명이 아니라, 안전 분석으로 식별된 롱테일 오경보 문제에 대해 이들 요소를 통합하고 충돌 예측 도메인에 적용한 데 있다.

본 연구의 한계는 다음과 같다. 첫째, 성능 수치는 비교 대상 선행 연구들과 동일하게 단일 학습 실행 기준으로 보고되었으며, 실제로 오경보에 대한 결론은 한 자리 수의 이벤트에 의존하므로 경향성의 범위에서 해석된다. 둘째, 목표 EIG 5.5는 문헌의 고불균형 수렴 조건($IF > 100$)에 근거해 사전 설정한 값으로, 목표값별 전체 재학습 비용의 제약으로 본 데이터셋 고유의 민감도 분석은 수행되지 않았으며(이 경우 보고된 개선은 제안 절차 성능의 보수적 하한에 해당한다), 군집 수 K 등 선별 하이퍼파라미터에 대한 민감도 분석 또한 이루어지지 않았다. 셋째, 선별 품질과 표본량 축소의 효과는 동일 규모의 무작위 선별 대조군(Case 9)을 통해 분리하였으나, 이 대조군은 단일 추출·단일 학습으로 수행되어 무작위 부분집합의 추출 변동은 반영되지 않았다. 넷째, 오경보 저감이 미검출 증가(43→68 건)를 수반하였다. 전체 오판단은 50 건 순감소하여 총량 관점의 손실은 없으나, 오경보와 미검출의 안전 위해도가 등가가 아니므로 미검출 증가분에 대한 잔여 회피 시간 기준의 위해도 정량 분석이 필요하다. 다섯째, 본 연구의 개입과 평가는 회전교차로 클래스에 한정되며, 또 다른 꼬리 클래스인 기타 도로 유형으로의 전이 가능성은 검증

하지 않았다. 이에 따라 목표 EIG 민감도 스윙과 미검출 증가분의 안전 위해도 정량 분석을 향후 연구 과제로 남긴다.

5. 참고 문헌

- [1] SAE International, "Taxonomy and Definitions for Terms Related to Driving Automation Systems for On-Road Motor Vehicles (J3016)," 2021.
- [2] UN Regulation No. 171, "Uniform Provisions Concerning the Approval of Vehicles with Regard to Driver Control Assistance Systems (DCAS)," United Nations Economic Commission for Europe (UNECE), Geneva, Switzerland, 2024.
- [3] J. B. Cicchino, "Effectiveness of forward collision warning and autonomous emergency braking systems in reducing front-to-rear crash rates," Accident Analysis & Prevention, vol. 99, pt. A, pp. 142–152, 2017.
- [4] European New Car Assessment Programme (Euro NCAP), "Assisted Driving: Highway Assist Systems — Test and Assessment Protocol," Version 2.1, Euro NCAP, 2023.
- [5] National Transportation Safety Board (NTSB), "Collision Between a Sport Utility Vehicle Operating With Partial Driving Automation and a Crash Attenuator, Mountain View, California, March 23, 2018," Highway Accident Report NTSB/HAR-20/01, Washington, DC, USA, 2020.
- [6] ISO 21448:2022, "Road vehicles — Safety of the intended functionality (SOTIF)," International Organization for Standardization, Geneva, Switzerland, 2022.
- [7] ISO/PAS 8800:2024, "Road vehicles — Safety and artificial intelligence," 1st ed., International Organization for Standardization, Geneva, Switzerland, Dec. 2024.
- [8] ISO 26262-3:2018, "Road vehicles — Functional safety — Part 3: Concept phase," 2nd ed., International Organization for Standardization, Geneva, Switzerland, 2018.

- [9] T. Menzel, G. Bagschik, and M. Maurer, "Scenarios for Development, Test and Validation of Automated Vehicles," 2018 IEEE Intelligent Vehicles Symposium (IV), pp. 1821–1827, 2018.
- [10] M. Scholtes et al., "6-Layer Model for a Structured Description and Categorization of Urban Traffic and Environment," IEEE Access, vol. 9, pp. 59131–59147, 2021, doi: 10.1109/ACCESS.2021.3072739.
- [11] P. Shepelev et al., "Procedural Generation of High-Definition Road Networks for Autonomous Vehicle Testing and Traffic Simulations," SAE International Journal of Connected and Automated Vehicles, vol. 6, no. 1, pp. 99–120, 2023, doi: 10.4271/12-06-01-0007.
- [12] O. Makansi, Ö. Çiçek, Y. Marrakchi, and T. Brox, "On Exposing the Challenging Long Tail in Future Prediction of Traffic Actors," in Proc. IEEE/CVF International Conference on Computer Vision (ICCV), 2021.
- [13] H. X. Liu and S. Feng, "Curse of rarity for autonomous vehicles," Nature Communications, vol. 15, art. no. 4808, 2024, doi: 10.1038/s41467-024-49194-0.
- [14] W. Dai, Y. Ma, J. Chen, X. Chen, and S. Li, "Tradeoffs Between Richness and Bias of Augmented Data in Long-Tail Recognition," Entropy, vol. 27, no. 2, art. no. 201, Feb. 2025, doi: 10.3390/e27020201.
- [15] Y. Zhang, B. Kang, B. Hooi, S. Yan, and J. Feng, "Deep Long-Tailed Learning: A Survey," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 45, no. 9, pp. 10795–10816, 2023, doi: 10.1109/TPAMI.2023.3268118.
- [16] N. Kaempchen, B. Schiele, and K. Dietmayer, "Situation assessment of an autonomous emergency brake for arbitrary vehicle-to-vehicle collision scenarios," IEEE Transactions on Intelligent Transportation Systems, vol. 10, no. 4, pp. 678–687, 2009.
- [17] K. Lee and D. Kum, "Collision avoidance/mitigation system: Motion planning of autonomous vehicle via predictive occupancy map," IEEE Access, vol. 7, pp. 52846–52857, 2019.
- [18] J. Jansson, "Collision avoidance theory: With application to automotive collision mitigation," Ph.D. dissertation, Linköping University Electronic Press, Linköping, Sweden, 2005.
- [19] A. Houenou, P. Bonnifait, V. Cherfaoui, and W. Yao, "Vehicle trajectory prediction based on motion model and maneuver recognition," in 2013 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pp. 4363–4369, 2013.

- [20] N. Deo and M. M. Trivedi, "Multi-modal trajectory prediction of surrounding vehicles with maneuver based LSTMs," in 2018 IEEE Intelligent Vehicles Symposium (IV), pp. 1179–1184, 2018.
- [21] S. Lee, B. Song, and J. Shin, "Collision prediction in an integrated framework of scenario-based and data-driven approaches," IEEE Access, vol. 12, pp. 55234–55247, 2024.
- [22] 이성우, 정영훈, 송봉섭, "위험 시나리오에 대한 트랜스포머 네트워크 기반 자율주행차량의 충돌 및 궤적 예측 알고리즘 개발," 한국자동차공학회논문집, 제 32 권, 제 10 호, pp. 843–852, 2024.
- [23] P. Chu, X. Bian, S. Liu, and H. Ling, "Feature space augmentation for long-tailed data," in Computer Vision – ECCV 2020, Part XXIX, Springer, pp. 694–710, 2020.
- [24] Y. Ma, L. Jiao, F. Liu, S. Yang, X. Liu, and P. Chen, "Feature distribution representation learning based on knowledge transfer for long-tailed classification," IEEE Transactions on Multimedia, pp. 1–14, 2023, doi: 10.1109/TMM.2023.3303697.
- [25] H.-P. Chou, S.-C. Chang, J.-Y. Pan, W. Wei, and D.-C. Juan, "Remix: Rebalanced Mixup," in Computer Vision – ECCV 2020 Workshops, Part VI, Springer, pp. 95–110, 2020.
- [26] S. Park, Y. Hong, B. Heo, S. Yun, and J. Y. Choi, "The Majority Can Help the Minority: Context-rich Minority Oversampling for Long-tailed Classification," in Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 6887–6896, 2022.
- [27] F. Bastani, S. He, S. Abbar, M. Alizadeh, H. Balakrishnan, S. Chawla, S. Madden, and D. DeWitt, "RoadTracer: Automatic Extraction of Road Networks from Aerial Images," in Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 4720–4728, 2018, doi: 10.1109/CVPR.2018.00496.
- [28] L. Mi, H. Zhao, C. Nash, X. Jin, J. Gao, C. Sun, C. Schmid, N. Shavit, Y. Chai, and D. Anguelov, "HDMaGen: A Hierarchical Graph Generative Model of High Definition Maps," in Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021.
- [29] J. Zhou, L. Wang, Q. Meng, and X. Wang, "DiffRoad: Realistic and Diverse Road Scenario Generation for Autonomous Vehicle Testing," arXiv preprint arXiv:2411.09451, 2024.
- [30] Z. Ikram, G. M. Mukhtadir, and J. Whitehead, "Procedural Generation of Complex Roundabouts for Autonomous Vehicle Testing," in 2023 IEEE Intelligent Vehicles Symposium (IV), pp. 1–6, 2023, doi: 10.1109/IV55152.2023.10186533.

- [31] Q. Li, Z. Peng, Q. Zhang, C. Liu, and B. Zhou, "Improving the Generalization of End-to-End Driving through Procedural Generation (PGDrive)," arXiv preprint arXiv:2012.13681, 2020.
- [32] 정영훈, 오나영, 송봉섭, 신장호, "차량 간 충돌 예측을 위한 실도로 및 가상 주행 데이터 기반 학습데이터 균형을 고려한 능동-커리큘럼 학습 연구," 한국자동차공학회 논문집, 제 34 권, 제 2 호, pp. 267–279, 2026.
- [33] Korea Road Traffic Authority (KoROAD), "Traffic Accident Analysis System (TAAS)," [Online]. Available: <https://taas.koroad.or.kr> (accessed Jun. 14, 2026).
- [34] IGLAD Consortium, "IGLAD Codebook, Member Year 2020 (Phase IV)," Initiative for the Global Harmonization of Accident Data, Feb. 2021. [Online]. Available: <https://iglad.org>.
- [35] C. Glasmacher, R. Krajewski, and L. Eckstein, "An Automated Analysis Framework for Trajectory Datasets," arXiv preprint arXiv:2202.07438, 2022.
- [36] O. Sener and S. Savarese, "Active Learning for Convolutional Neural Networks: A Core-Set Approach," in Proc. International Conference on Learning Representations (ICLR), 2018.
- [37] P. W. Koh and P. Liang, "Understanding Black-box Predictions via Influence Functions," in Proc. 34th International Conference on Machine Learning (ICML), pp. 1885–1894, 2017.
- [38] A. Ghorbani and J. Zou, "Data Shapley: Equitable Valuation of Data for Machine Learning," in Proc. 36th International Conference on Machine Learning (ICML), pp. 2242–2251, 2019.
- [39] R. Krajewski, T. Moers, J. Bock, L. Vater, and L. Eckstein, "The roundD Dataset: A Drone Dataset of Road User Trajectories at Roundabouts in Germany," in 2020 IEEE 23rd International Conference on Intelligent Transportation Systems (ITSC), pp. 1–6, 2020.